



UNIVERSIDAD TORCUATO DI TELLA
ESCUELA DE NEGOCIOS

Intro a ciencia de datos

Prof. Pablo Roccatagliata

Maestría en Finanzas


CONTENIDOS PARTE III

- Algunas ideas más sobre análisis exploratorio de datos (EDA)
- ¿Qué es una visualización de datos?
- No es magia! Principios para data viz
- Estrategias para visualizar data en 1D...hasta 6D
 - Introducir el problema de reducción de dimensionalidad
 - Análisis de componentes principales
- Interpretabilidad
- Aplicaciones en finanzas



ANÁLISIS EXPLORATORIO DE DATOS(EDA)

- La semana pasada cubrimos (entre otras cosas) algunos pasos necesarios de análisis exploratorio de datos..
 - Check cantidad de columnas y filas
 - Check tipo de dato de la columna
 - Estadísticas descriptivas (con conteo de missings) mediante el widget feature statistics.
 - Visualizaciones (histogramas para ver los picos, cdf para ver las colas)



- ¿Cómo debería ser la distribución de cada variable? Es importante tener una idea preconcebida de cualquier resultado para ayudar a detectar anomalías.
- Filtramos outliers (boxplot o más avanzado local outlier factor)

CODIFICACIÓN CATEGÓRICAS

- La semana pasada cubrimos (entre otras cosas) algunos pasos necesarios de análisis exploratorio de datos..
- Recodificamos categóricas (one hot enconding). Es un ejemplo de feature engineering.

OneHot Encoding

workclass		State-gov	Self-emp-not-inc	Private
State-gov		1	0	0
Self-emp-not-inc		0	1	0
Private		0	0	1
Private		0	0	1
Private		0	0	1

CODIFICACIÓN CATEGÓRICAS

- La semana pasada cubrimos (entre otras cosas) algunos pasos necesarios de análisis exploratorio de datos..
 - Recodificamos categóricas (one hot encoding). Es un ejemplo de feature engineering. ¿Qué pasa si tenemos muchas categóricas con múltiples niveles?

$$\begin{pmatrix} 0 & \dots & 0 & 1 \\ \vdots & 0 & 0 & \vdots \\ & & \ddots & \\ 0 & 1 & 0 & 0 \\ 1 & \dots & & 0 \end{pmatrix}$$

- [Memoria y tiempo de cómputo...](#)

CODIFICACIÓN CATEGÓRICAS

- La semana pasada cubrimos (entre otras cosas) algunos pasos necesarios de análisis exploratorio de datos..
- Recodificamos categóricas (one hot encoding). Es un ejemplo de feature engineering. ¿Qué pasa si tenemos muchas categóricas con múltiples niveles?

A sparse matrix format					B corresponding full matrix								
	row	column	weight	sign		0	1	2	3	4	5	6	7
0	1	2	1.5	1	0	0	0	0	0	0	0	0	0
1	1	6	4	-1	1	0	0	1.5	0	0	0	-4	0
2	3	4	0.3	1	2	0	0	0	0	0	0	0	0
3	4	6	1	-1	3	0	0	0	0	0.3	0	0	0
4	6	2	2	1	4	0	0	0	0	0	0	-1	0
					5	0	0	0	0	0	0	0	0
					6	0	0	2	0	0	0	0	0
					7	0	0	0	0	0	0	0	0

- [Dense vs Sparse matrix](#)
- [Solución...](#)

CODIFICACIÓN CATEGÓRICAS

- Otra alternativa para la recodificación.."target encoding"
 - <https://www.kaggle.com/code/ryanholbrook/target-encoding>

	make	price	make_encoded
0	alfa-romero	13495	15498.333333
1	alfa-romero	16500	15498.333333
2	alfa-romero	16500	15498.333333
3	audi	13950	17859.166667
4	audi	17450	17859.166667
5	audi	15250	17859.166667
6	audi	17710	17859.166667
7	audi	18920	17859.166667
8	audi	23875	17859.166667
9	bmw	16430	26118.750000

- <https://scikit-learn.org/dev/modules/generated/sklearn.preprocessing.TargetEncoder.html>

MOTIVACIÓN

- La semana pasada cubrimos (entre otras cosas) algunos pasos necesarios de análisis exploratorio de datos..
 - ¿Qué otros problemas podríamos haber encontrado?
 - Unit conversions
 - Number / character code representations
 - Name unification
 - Time/date unification
 - Financial unification

MOTIVACIÓN

- La semana pasada cubrimos (entre otras cosas) algunos pasos necesarios de análisis exploratorio de datos..
 - ¿Qué otros problemas podríamos haber encontrado? Missing values..
 - No borrarlos!
 - Una posibilidad es imputar (Mean value imputation, Random value imputation, Imputation by interpolation)
 - Idea: si los missings son informativos entonces la ausencia del dato puede transformarse en un feature más que debería mejorar la performance predictiva. En Orange pueden usar widget feature constructor.
 - Ejemplo..

edad	ingreso	ingreso_inputado	dummie_falta ingreso
24	100	100	0
34	?	0	1

STANDARD DATA FORMATS

- Otro problemas puede ser tener que incorporar distintos formatos
 - CSV files: para tablas como las hojas de cálculo..
 - XML: para data estructurada pero no tabular

```
<part number="1976">
  <name>Windscreen Wiper</name>
  <description>The Windscreen wiper
    automatically removes rain
    from your windscreen, if it
    should happen to splash there.
    It has a rubber <ref part="1977">blade</ref>
    which can be ordered separately
    if you need to replace it.
  </description>
</part>
```

[Fuente imagen](#)

STANDARD DATA FORMATS

- Otro problemas puede ser tener que incorporar distintos formatos
 - JSON: Javascript Object Notation para APIs.

```
JSON
{
  "firstName": "Jane",
  "lastName": "Doe",
  "hobbies": ["running", "sky diving", "singing"],
  "age": 35,
  "children": [
    {
      "firstName": "Alice",
      "age": 6
    },
    {
      "firstName": "Bob",
      "age": 8
    }
  ]
}
```

[Fuente imagen](#)



MERGE, APPEND, JOIN, UNION..ETC.

- O [más de una tabla...](#)

	employee	group
0	Bob	Accounting
1	Jake	Engineering
2	Lisa	Engineering
3	Sue	HR

	employee	hire_date
0	Lisa	2004
1	Bob	2008
2	Jake	2012
3	Sue	2014

```
pd.merge(df1, df2, on='employee')
```

	employee	group	hire_date
0	Bob	Accounting	2008
1	Jake	Engineering	2012
2	Lisa	Engineering	2004
3	Sue	HR	2014

MOTIVACIÓN

- Luego seguimos los pasos.. más vinculado al entrenamiento de un modelo..
 - Elegimos un target
 - Hicimos Split train y test
 - Normalizamos features (y no el target!)
 - Optimizamos hiper parámetros vía cross validación.
- Entrenamos el modelo de regresión logística (obtuvimos estimaciones para los beta).



MOTIVACIÓN

*make **both** calculations **and** graphs. Both sorts of output should be studied; each will contribute to understanding.*


F. J. Anscombe, 1973

(and echoed in nearly all talks about data visualization...)

'The Datasaurus Dozen'

*Can you guess what is
common among these
very different looking
sets of data?*






<https://www.autodeskresearch.com/publications/samestats>

Why Data Visualization

Introducing The Datasaurus Dozen!



What is common in all these images?

Ans: Summary Stats are the same!

X Mean:	54.26
Y Mean:	47.83
X SD :	16.76
Y SD :	26.93
Corr. :	-0.06

Anscombe's Quartet

All the summary statistics you'd think to compute are close to identical:

The average x value is 9 for each dataset

The average y value is 7.50 for each dataset

The variance for x is 11 and the variance for y is 4.12

The correlation between x and y is 0.816 for each dataset

A linear regression (line of best fit) for each dataset follows the equation $y = 0.5x + 3$


How do they look?

Why Data Visualization


Introducing Anscombe's Quartet

Anscombe's Quartet

Each dataset has the same summary statistics (mean, standard deviation, correlation), and the datasets are *clearly different*, and *visually distinct*.




Three varying 1D distributions of data, all with the same boxplot representation.




Seven distributions of data, shown as raw data points (or strip-plots), as box-plots, and as violin-plots.


Raw Data



Box-plot of the Data



Violin-plot of the Data



MOTIVACIÓN


¿Cumple el objetivo la tabla de datos?

	A	B	C	D	E	F	G
1	YEAR	TEMP	YEAR	1 SIGMA	2 SIGMA		
2	1000	0.0659	1000	0.240346	0.480693	0.206137	0.123588
3	1001	-0.1241	1001	0			
4	1002	-0.1208	1002	0			
5	1003	-0.1801	1003	0			
6	1004	-0.0711	1004	0			
7	1005	-0.1334	1005	0			
8	1006	-0.0644	1006	0			
9	1007	0.0042	1007	0			
10	1008	-0.1288	1008	878	1876	-0.1891	1876
11	1009	-0.0296	1009	879	1877	-0.0140	1877
12	1010	0.1187	1010	880	1878	-0.0873	1878
13	1011	-0.1252	1011	881	1879	-0.2959	1879
14	1012	-0.1634	1012	882	1880	-0.2368	1880
15	1013	-0.0791	1013	883	1881	-0.1977	1881
16	1014	-0.1120	1014	884	1882	-0.2036	1882
17	1015	-0.1146	1015	885	1883	-0.2489	1883
18	1016	-0.1206	1016	886	1884	-0.2125	1884
19	1017	-0.0815	1017	887	1885	-0.1896	1885
20	1018	-0.2031	1018	888	1886	-0.1084	1886
21	1019	0.0305	1019	889	1887	-0.3265	1887
22	1020	0.1098	1020	890	1888	-0.1694	1888
23	1021	0.0244	1021	891	1889	-0.1339	1889
24	1022	-0.0743	1022	892	1890	-0.3107	1890
25	1023	-0.0323	1023	893	1891	-0.1754	1891
26	1024	-0.0434	1024	894	1892	-0.3186	1892
				895	1893	-0.3236	1893
				896	1894	-0.1970	1894
				897	1895	-0.1578	1895
				898	1896	-0.0804	1896
				899	1897	-0.0537	1897
				900	1898	-0.2195	1898
				901	1899	-0.3486	1899
				902	1900	-0.1253	1900
				903	1901	-0.1575	1901

Fuente:Alberto Cairo


MOTIVACIÓN

Una visualización es una representación diseñada para permitir la exploración, el descubrimiento o la comunicación.



Fuente:Alberto Cairo

MOTIVACIÓN




Fuente: Alberto Cairo

MOTIVACIÓN

COMPLETE CHART

MURDERS

Rate per 100,000 people (2015)




0 3 6 9 >9
Source: FBI Uniform Crime Reports

FRAMEWORK

MURDERS

Rate per 100,000 people (2015)




0 3 6 9 >9
Source: FBI Uniform Crime Reports

CONTENT (ENCODING)

MURDERS

Rate per 100,000 people (2015)




0 3 6 9 >9
Source: FBI Uniform Crime Reports

COMPLETE CHART

MURDERS

Rate per 100,000 people



Source: FBI Uniform Crime Reports

FRAMEWORK

MURDERS

Rate per 100,000 people



Source: FBI Uniform Crime Reports

CONTENT (ENCODING)

MURDERS

Rate per 100,000 people



Source: FBI Uniform Crime Reports

SPECIFIC GRAPHS, LAYOUTS, AND AXIS STYLES

¿ Qué quiero mostrar? ¿ Para qué tipo de dato?

Bars

Histogramas

Line graphs

Time series

Pie graphs

Scatter plots

Tables

Tree maps




Figure 5-7. Good pie graphs, with few wedges and low need for precision.




Figure 5-8. Circular areas used to represent and compare quantities per region on a map.




Figure 5-6. Wind roses show frequency and speed of wind by direction.

MOTIVACIÓN


Length or height



Position



Area




Angle/area



Line weight



Hue and shade



Figures represented
in all these graphics:
22%, 25%, 34%, 29%, 32%

Visual encoding

El estilo y la estructura de una visualización dependen del propósito!

SPECIFIC GRAPHS, LAYOUTS, AND AXIS STYLES



Fuente: Alberto Cairo

<https://datavizcatalogue.com/>



<https://depictdatastudio.com/charts/>


SPECIFIC GRAPHS, LAYOUTS, AND AXIS STYLES



Fuente: Alberto Cairo


<https://ft-interactive.github.io/visual-vocabulary/>

ENCODING HIERARCHY




¿ [What do you want to show?](#)

ENCODING HIERARCHY




Inspired by Cleveland and McGill (1984)

ENCODING HIERARCHY



Inspired by Cleveland and McGill (1984)


MOTIVACIÓN



Graphics based on length, height, and position along common axes:
Great for accurate estimates

El estilo y la estructura de una visualización dependen del propósito!

MOTIVACIÓN



Other methods of encoding (size, area, color, etc.):
Great for the big picture, but not so much for accuracy


El estilo y la estructura de una visualización dependen del propósito!

MOTIVACIÓN

EUROPEAN COMMISSION

Figure 2 - Main nationalities of arriving migrants – 2016


Greece



Fuente:Alberto Cairo

MOTIVACIÓN

EUROPEAN COMMISSION




Fuente: Alberto Cairo

MOTIVACIÓN

How Music Preferences Have Changed in Two Decades


Music styles preferred by University of Miami students. Survey based on interviews with 1,000 students.
SOURCE: WishfulThinkingData Inc.



¿Cuál es mejor para ver cambios en el tiempo?

How Music Preferences Have Changed in Two Decades

Music styles preferred by University of Miami students. Survey based on interviews with 1,000 students.
SOURCE: WishfulThinkingData Inc.




Fuente:Alberto Cairo

El estilo y la estructura de una visualización dependen del propósito!

MOTIVACIÓN

La visualización se ha vuelto mainstream...


[The largest vocabulary in Hip Hop](#)



MINI EJERCICIO


Esta es probablemente la visualización más reproducida en las últimas semanas...

<https://coronavirus.jhu.edu/map.html>



MINI EJERCICIO

- [Esta es probablemente la visualización más reproducida en las últimas semanas...](#)
- Nos dividimos en grupos en las break-out rooms de zoom
 - ¿Encuentra algún problema en la visualización?
 - [Information is beautiful](#). Mejor no?



**¿Cómo generar
estas
visualizaciones?**
No es magia!




Good graphics...

1. ...Are based on good data
2. ...Attract your attention
3. ...Represent the data accurately
4. ...Show the right amount of data

Estrategias para visualizar datos



Visualizing Structured Multi-Dimensional Data



Wine Quality Data Set disponible en
UCI Machine Learning Repository.

Start with the Data - as always!

Dataset is based on various properties of red and white wine


```
wines.head()
```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality	wine_type	quality_label
0	7.0	0.17	0.74	12.8	0.045	24.0	126.0	0.99420	3.26	0.38	12.2	8	white	high
1	7.7	0.64	0.21	2.2	0.077	32.0	133.0	0.99560	3.27	0.45	9.9	5	red	low
2	6.8	0.39	0.34	7.4	0.020	38.0	133.0	0.99212	3.18	0.44	12.0	7	white	medium
3	6.3	0.28	0.47	11.2	0.040	61.0	183.0	0.99592	3.12	0.51	9.5	6	white	medium
4	7.4	0.35	0.20	13.9	0.054	63.0	229.0	0.99888	3.11	0.50	8.9	6	white	medium

Basic Descriptive Statistics


Red Wine Statistics							White Wine Statistics					
	residual sugar	total sulfur dioxide	sulphates	alcohol	volatile acidity	quality	residual sugar	total sulfur dioxide	sulphates	alcohol	volatile acidity	quality
count	1599.00	1599.00	1599.00	1599.00	1599.00	1599.00	4898.00	4898.00	4898.00	4898.00	4898.00	4898.00
mean	2.54	46.47	0.66	10.42	0.53	5.64	6.39	138.36	0.49	10.51	0.28	5.88
std	1.41	32.90	0.17	1.07	0.18	0.81	5.07	42.50	0.11	1.23	0.10	0.89
min	0.90	6.00	0.33	8.40	0.12	3.00	0.60	9.00	0.22	8.00	0.08	3.00
25%	1.90	22.00	0.55	9.50	0.39	5.00	1.70	108.00	0.41	9.50	0.21	5.00
50%	2.20	38.00	0.62	10.20	0.52	6.00	5.20	134.00	0.47	10.40	0.26	6.00
75%	2.60	62.00	0.73	11.10	0.64	6.00	9.90	167.00	0.55	11.40	0.32	6.00
max	15.50	289.00	2.00	14.90	1.58	8.00	65.80	440.00	1.08	14.20	1.10	9.00

Univariate Analysis - Visualizing 1-D




Univariate Analysis - Visualizing 1-D

Visualizing a continuous numeric attribute



Univariate Analysis - Visualizing 1-D


Visualizing a continuous numeric attribute



Univariate Analysis - Visualizing 1-D

Visualizing a discrete categorical attribute



Wine Quality Frequency




TRANSFORMACIONES

Log-lineal

- Podemos comparar variables en escalas diferentes
- Transformar relaciones exponenciales en lineales



Quantile Plots (QQ Plots)....



**...Clearly
Explained!!!!**

[Link](#)


Los gráficos cuantil-cuantil (qq-plots) nos ayudan a comparar la distribución de un conjunto de datos con

- la de otro conjunto de datos o
- con una distribución teórica.

¿Cómo se ve el gráfico si ambos conjuntos de datos tienen la misma distribución?



Multivariate Analysis - Visualizing 2-D

Visualizing feature correlations




Multivariate Analysis - Visualizing 2-D

Visualizing numeric features




Multivariate Analysis - Visualizing 2-D

Visualizing numeric features - use a pairplot




Multivariate Analysis - Visualizing 2-D

Visualizing two categorical attributes - A pain with matplotlib!




Multivariate Analysis - Visualizing 2-D

Visualizing two categorical attributes - easier and cleaner with seaborn




Multivariate Analysis - Visualizing 2-D

Visualizing a mix of categorical & numeric attributes




Multivariate Analysis - Visualizing 2-D

Visualizing a mix of categorical & numeric attributes




Multivariate Analysis - Visualizing 2-D

Visualizing a mix of categorical & numeric attributes - more categories? use box-plots or violin plots



Another similar visualization is violin plots


¿En qué se diferencia el violin plot del boxplot?



Visualizing data in Three Dimensions (3-D)



Multivariate Analysis - Visualizing 3-D

Visualizing numeric attributes - is this effective?




Multivariate Analysis - Visualizing 3-D

Visualizing numeric attributes - bin one or more attributes and use facets, color and/or size




Multivariate Analysis - Visualizing 3-D

Visualizing numeric attributes - bin one or more attributes and use facets, color and/or size





Multivariate Analysis - Visualizing 3-D

Visualizing categorical attributes using facets and color




Multivariate Analysis - Visualizing 3-D

Visualizing mixed attributes




Visualizing mixed attributes in three-dimensions leveraging split violin plots and the concept of **hue**



Multivariate Analysis - Visualizing 3-D


Visualizing mixed attributes



Visualizing data in Four Dimensions (4-D)


Multivariate Analysis - Visualizing 4-D

Visualizing mixed attributes (more numeric variables)




Multivariate Analysis - Visualizing 4-D

Visualizing mixed attributes (more numeric variables) - need to bin one numeric variable




Multivariate Analysis - Visualizing 4-D

Visualizing mixed attributes




Multivariate Analysis - Visualizing 5-D

Visualizing mixed attributes - not always effective



Multivariate Analysis - Visualizing 5-D


Visualizing mixed attributes - start with faceting and sizes



Multivariate Analysis - Visualizing 5-D


Visualizing mixed attributes - multi-facets often better than size (often needs binning of numerics)

Wine Type - Sulfur Dioxide - Residual Sugar - Alcohol - Quality




Multivariate Analysis - Visualizing 6-D

Visualizing mixed attributes - color, size, shape & depth



Multivariate Analysis - Visualizing 6-D

Visualizing mixed attributes - color, size & multi-facets



¿PODEMOS IR MAS ARRIBA CON LA CANTIDAD DE DIMENSIONES?

- Definitivamente se hace cada vez más difícil sortear las limitaciones de un dispositivo de representación bidimensional para visualizar más dimensiones de datos.
- Un método es usar más facets y subplots
- Además de esto, también puede usar la noción de tiempo si su conjunto de datos tiene un aspecto temporal




MOTIVACIÓN

*The world cannot be understood **without numbers**.
And it cannot be understood **with numbers alone**.*

—[HANS ROSLING](#), *FACTFULNESS* (2018)

[World GDP](#)

MOTIVACIÓN



Life expectancy ▾

years

90

80

70

60

50

40

30

20

INCOME LEVEL 1

LEVEL 2

LEVEL 3

LEVEL 4

2020

Size: Population, total, Color: World Regions

per person (GDP/capita, PPP\$ inflation-adjusted)

500100020004000800016k32k64k


Income ▾

180019002000

DATA DOUBTS

¿PODEMOS SUBIR LA CANTIDAD DE DIMENSIONES?

- Técnicas de reducción de dimensionalidad como PCA, etc.



- Usar conocimiento del dominio para focalizarse en features importantes
- Recuerde reescalar features y remover outliers

REDUCCIÓN DE DIMENSIONALIDAD


- PCA es una técnica de reducción de dimensionalidad
- Buscamos construir componentes principales como promedios ponderados de *todas las columnas*.
- Tantos componentes posibles como columnas tenga la matriz a reducir.
- Buscamos minimizar la pérdida de información

REDUCCIÓN DE DIMENSIONALIDAD

PCA

- Para facilitar la visualización
- Data compression
- Descorrelacionar features
- Denoising


REDUCCIÓN DE DIMENSIONALIDAD



¿Cómo podemos escribir el primer componente principal?

$$Z_1 = 0.839 \times (\text{pop} - \overline{\text{pop}}) + 0.544 \times (\text{ad} - \overline{\text{ad}})$$

REDUCCIÓN DE DIMENSIONALIDAD



$$z_{i1} = 0.839 \times (\text{pop}_i - \overline{\text{pop}}) + 0.544 \times (\text{ad}_i - \overline{\text{ad}})$$



¿Cómo podemos escribir el puntaje del primer componente principal para una observación particular?

$$z_{i1} = 0.839 \times (\text{pop}_i - \overline{\text{pop}}) + 0.544 \times (\text{ad}_i - \overline{\text{ad}})$$

REDUCCIÓN DE DIMENSIONALIDAD

$$Z_2 = 0.544 \times (\text{pop} - \overline{\text{pop}}) - 0.839 \times (\text{ad} - \overline{\text{ad}})$$

¿Necesito el segundo componente principal en este caso?



REDUCCIÓN DE DIMENSIONALIDAD

$$\begin{bmatrix} \sigma_1^2 & \text{cov}(1,2) & \text{---} & \text{cov}(1,n) \\ \text{cov}(2,1) & \text{---} & \text{---} & \text{---} \\ \text{---} & & \text{---} & \text{---} \\ \text{cov}(n,1) & \text{cov}(n,2) & \text{---} & \sigma_n^2 \end{bmatrix}$$

¿Cómo podríamos usar la matriz de varianza y covarianza para medir la pérdida de información?


REDUCCIÓN DE DIMENSIONALIDAD

$$\text{minimize} = \frac{1}{2N} \sum_{n=1}^N \|x_n - \hat{x}_n\|^2$$

$$\hat{x} = Wx + \text{const}$$


Otra forma de ver PCA. Como un problema de reconstruir la matriz X original a partir de la versión reducida

REDUCCIÓN DE DIMENSIONALIDAD



Otra forma de ver PCA. Como un problema de reconstruir la matriz X original a partir de la versión reducida

REDUCCIÓN DE DIMENSIONALIDAD



¿Cómo elegimos la cantidad de componentes principales?

REDUCCIÓN DE DIMENSIONALIDAD

PCA

- Hay que establecer un método para determinar la cantidad de componentes.
 - ¿Validación cruzada
 - mirar la curva de varianza explicada cuando hacemos análisis exploratorio
 - Idealmente encontrar patrones interesantes en los primeros componentes principales
- No necesariamente una buena idea para crear features para predecir un target Y .
 - Alternativa partial least squares.

REDUCCIÓN DE DIMENSIONALIDAD


age	gender	civil_status	salary	has_children	available_credit
21	M	MARRIED	3000	TRUE	2200
21	M	SINGLE	1200	FALSE	100
19	N	SINGLE	32000	TRUE	22000
30	M	SINGLE	1800	TRUE	1100
21	F	MARRIED	2900	TRUE	2000
21	F	SINGLE	1100	FALSE	100
19	F	WIDOW	10000	FALSE	6000
30	F	DIVORCED	1500	TRUE	2200

¿Funciona PCA con un mix features cuantitativos y no cuantitativos?

- Si, ver [PCAmix](#)!
- Si solo tengo cualitativas usar MCA.

REDUCCIÓN DE DIMENSIONALIDAD

US Treasury Yield Curves



REDUCCIÓN DE DIMENSIONALIDAD

Market yield on U.S. Treasury securities					
date	1 month	3 month	6 month	1 year	
7/15/2019	2.17	2.16	2.06	1.95	
7/16/2019	2.16	2.15	2.06	2	
7/17/2019	2.13	2.14	2.04	1.95	

¿Recuerdan las combinaciones lineales?

TERM STRUCTURE MODELS

- 1 Factor models (Vasicek, Ho-Lee)
 - Modelar la tasa corta (factor), derivar el resto de la curva de ella.
- **Vasicek's model** is a single-factor model of the term structure that assumes constant volatility and that the short-term interest rate drifts toward a prespecified long-term mean level. The model specifies the following mean-reverting process for the short-term rate of interest:

$$\tilde{r}_{t+1} = r_t + \kappa (\mu - r_t) + \sigma \tilde{\varepsilon}_{t+1}$$

TERM STRUCTURE MODELS

- 1 Factor models (Vasicek, Ho-Lee)
 - Modelar la tasa corta (factor), derivar el resto de la curva de ella.
- **Cox, Ingersoll, and Ross model** (CIR model) is a single-factor model that alters the Vasicek model to make the variance of the short-term interest rate proportional to the rate itself, thereby disallowing negative interest rates. In other words, negative rates are prevented because as rates approach zero, their volatility approaches zero. The following equation represents the short-term interest rate process proposed by the CIR model:


$$r_{t+1} = r_t + \kappa (\mu - r_t) + \sqrt{r_t} \sigma \tilde{\varepsilon}_{t+1}$$

The major difference between this model and Vasicek's is that the variance of the change in the short-term rate, is proportional to the short-term rate. This makes sense, as we observe higher volatility for interest rate changes when the short-term rate is relatively high.

TERM STRUCTURE MODELS

- **Heath–Jarrow–Morton (HJM)**
 - Modelar la curva complete
 - Muchos puntos!
 - Pero hay correlaciones entre ellos..
 - Quizá los movimientos viven "live" en un lower dimensional space.
- [Litterman-Scheikman \(1991\)](#)
 - 3 factores: Level-Slope-Curvature


REDUCCIÓN DE DIMENSIONALIDAD



[Fuente imagen](#)

¿Qué representarían estos factores?

DÓNDE BUSCAR INSPIRACIÓN...



FEATURE IMPORTANCE

- Entender qué features contribuyeron a la performance del modelo
 - Are these features important all the time, or only in some specific environments?
 - What triggers a change in importance over time?
 - Can those regime switches be predicted?
 - Are those important features also relevant to other related financial instruments?
 - Are they relevant to other asset classes?
 - What are the most relevant features across all financial instruments?
 - What is the subset of features with the highest rank correlation across the entire investment universe?

**SNIPPET 8.1 MARCOS' FIRST LAW OF
BACKTESTING—IGNORE AT YOUR OWN PERIL**


“Backtesting is not a research tool. Feature importance is.”

—Marcos López de Prado

Advances in Financial Machine Learning (2018)

INTERPRETABILIDAD DE LOS ALGORITMOS DE MACHINE LEARNING

- Características de los métodos de interpretabilidad
 - Intrínseco o post hoc?
 - Resultado (output) del método de interpretabilidad
 - Específico a un modelo o agnóstico
 - Local o global





[Fuente imagen](#)

INTERPRETABILIDAD DE LOS ALGORITMOS DE MACHINE LEARNING

- Alcance de la interpretabilidad

Transparencia del algoritmo ¿Cómo el algoritmo crea el modelo? Vs ¿Qué hace el modelo entrenado? Para jugar.. <http://playground.tensorflow.org>



INTERPRETABILIDAD DE LOS ALGORITMOS DE MACHINE LEARNING

Estrategias posibles

- ver partes del modelo (la caja negra)
 - ver sensibilidad sin mirar partes de la caja
 - cambio inputs para ver como cambian los outputs
 - solo tengo que poder evaluar la función (la caja negra)
- explicar casos individuales: lime y shap (los veremos al final)
- surrogate models (lime es surrogate localmente)
- global feature importance and effect
 - partial dependance plot por ejemplo
 - Feature importance
- Saliency maps (imágenes)




FEATURE IMPORTANCE


- ¿Están correlacionados los features? Es lo que LDP llama substitution effects
 - A substitution effect takes place when the estimated importance of one feature is reduced by the presence of other related features.
- Podemos ortogonalizar los features para evitar este problema..
 - Pca
 - No nos olvidemos de estandarizar antes!
 - orthogonalization también puede usarse para reducir la dimensionalidad de la matriz X , esto ayuda en la convergencia de los algoritmos de ML
 - Análisis sobre features diseñados para explicar la estructura de los datos
 - Regresiones auxiliares etc

FEATURE IMPORTANCE

¿Cómo evitamos dependencias entre los features?




Proyección vector $\mathbf{a}$ sobre el vector $\mathbf{b}$:
obtenemos el component del vector $\mathbf{a}$
que se ubica en la direcciónn del
vector $\mathbf{b}$.



Proyección ortogonal : componente
del vector $\mathbf{v}$ que es perpendicular al
vector $\mathbf{s}$.


FEATURE IMPORTANCE



¿Qué esperarías ver en este scatter dada la forma en que PCA elige los componentes?


ESTRATEGIAS PARA LA INTERPRETABILIDAD

- *¿Qué es feature importance?*
 - *Grado en que un modelo predictivo se apoya en un feature particula*
 - *Muchas formas de medirlo*
 - *En árboles Mean decrease impurity por mean decrease en RSS*



FEATURE IMPORTANCE


- Podemos calcular (entre otros)
 - Mean Decrease Impurity
 - Mean Decrease Accuracy (Permutation importance)
- parallelized vs. stacked feature importance



	RD Spend	Administration	Marketing Spend	Profit	state_California
1	165349.2	136897.8	471784.1	192261.83	0
2	162597.7	151377.59	443898.53	191792.06	1
3	153441.51	101145.55	407934.54	191050.39	1
...	...	...	...	...	...
48	0	135426.92	0	42559.73	1
49	542.05	51743.15	0	35673.41	0
50	0	116983.8	45173.06	14681.4	1




¿GRAN VOLUMEN DE PUNTOS?

- ¿Qué problemas aparecen al querer visualizar billones de puntos?
 - [Plotting pitfalls: common problems when plotting large datasets, and how to avoid them. James A. Bednar.](#)
 - [Visualizing Billions of Data Points: Doing it Right](#)



US Census data (300 millones de puntos)

INSPIRACIÓN PARA ESTE CURSO...



A continuación...

Regularización y resampling




¿Preguntas?



Gracias!



proccatagliata@gmail.com



Gallery. M.C. Escher

Anexo

Hashing trick

MÁS FEATURE ENGINEERING

Otro truco mucho más avanzado (post curso)..hashing trick.

- <https://www.oreilly.com/library/view/advanced-machine-learning/9781771374927/video225457.html>

- https://scikit-learn.org/stable/auto_examples/text/plot_hashing_vs_dict_vectorizer.html#sphx-glr-auto-examples-text-plot-hashing-vs-dict-vectorizer-py

- https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.FeatureHasher.html

- <https://arxiv.org/abs/1805.08539>

- [Se usa en problemas de online learning](#)
 - <https://vowpalwabbit.org/>



Anexo

Data Viz

CONTENIDOS INTRO DATA VIZ

- Clasificación de visualizaciones
 - Complejidad
 - Infographics vs data viz
 - Exploration vs explanation
 - Designer-reader-data trinity
- Ingredientes de las visualizaciones exitosas
- Eligiendo encodings visuales apropiados
 - Place
 - Color
 - Size
 - Text
 - Shape
- Ejercicios conceptuales
- Ejemplo reducción dimensionalidad reunión 1
- Trampas a evitar



MOTIVACIÓN

Pretty much anyone can put some data into a graphing application (for example, Excel) and create a graph. This is important to consider, so I will repeat myself: anyone can put some data into a graphing application and create a graph.

This is remarkable, considering that the process of creating a graph was historically reserved for scientists or those in other highly technical roles.

And scary, because without a clear path to follow, our best intentions and efforts (combined with oft-questionable tool defaults) can lead us in some really bad directions: 3D, meaningless color, pie charts.

MOTIVACIÓN

- La visualización:

- aprovecha las increíbles capacidades y el ancho de banda del sistema visual para mover una gran cantidad de información al cerebro muy rápidamente.
- el "software" integrado de nuestro cerebro para identificar patrones y comunicar relaciones y significados.
- puede inspirar nuevas preguntas y una mayor exploración. La visualización ayuda a identificar subproblemas.



90% of information transmitted to the human brain is visual



The human brain processes visuals 60K times faster than text




65% of humans are visual learners



The human brain can process an observed visual in 13 - 80 ms

MOTIVACIÓN

- Una forma de clasificar una visualización es contando cuántas diferentes dimensiones de los datos se representan



La forma de tener éxito frente a este desafío es ser intencional sobre qué propiedad usar para cada dimensión e iterar o cambiar las codificaciones a medida que evoluciona el diseño.

VISUALIZACIÓN VS INFOGRAFÍAS




Figure 1-2. The difference between infographics and data visualization may be loosely determined by the method of generation, the quantity of data represented, and the degree of aesthetic treatment applied.

Fuente: Iliinsky, Steele

VISUALIZACIÓN VS INFOGRAFÍAS

Infografías

- manually drawn
- specific to the data at hand
- aesthetically rich
- relatively data-poor





Figure 1-3. Flint Hahn's Burning Man infographic is a great example of an aesthetically rich, manually-drawn piece.

VISUALIZACIÓN VS INFOGRAFÍAS

Data Viz

- algorithmically drawn
- easy to regenerate with different data
- often aesthetically barren
- relatively data-rich
- two categories of data visualization: **exploration and explanation.**
 - Híbridos: Explicación exploratoria: implica un conjunto de datos ya curados que, no obstante, se presenta con la intención de permitir una exploración por parte del lector. Estas visualizaciones suelen ser **interactivas**

Fuente: Iliinsky, Steele



https://trends.google.com/trends/story/US_cu_6fXtAFIBAABWdM_en

HYBRIDS

- ¿Para qué necesitamos interactividad?

- Amigable al usuario inexperto

- Estimular la acción informada


- Contar una historia

- Tomemos estos puntos para la práctica 2 de Plotly!

What's Really Warming the World?

By Eric Roston and Blacki Migliorzi | June 24, 2015

Skeptics of manmade climate change offer various natural causes to explain why the Earth has warmed 1.4 degrees Fahrenheit since 1880. But can these account for the planet's rising temperature? Scroll down to see how much different factors, both natural and industrial, contribute to global warming, based on findings from NASA's Goddard Institute for Space Studies.




<https://www.bloomberg.com/graphics/2015-whats-warming-the-world/>

PRESENTACIÓN DE RESULTADOS

Postulamos que hay tres categorías principales de visualizaciones explicativas basadas en las relaciones entre los tres actores necesarios: el diseñador, el lector y los datos.


Diseño basado en las relaciones predominantes de la triada RDD




¿Cómo se vincula este esquema con la diferencia entre exploration y explanation?

Figure 1-4. The nature of the visualization depends on which relationship (between two of the three components) is dominant.

PERSUASIVA



Fuente: Steele




[Fuente imagen](#)

LOS INGREDIENTES DE LAS VISUALIZACIONES EXITOSAS

(aplican principalmente a visualizaciones exploratorias)

- 1. Diseñador:
 - Tienes una meta!
- ¿Por qué estás aquí? Informa decisiones y nos da un standard para evaluar.
 - ¿Qué experiencia debería proveer al lector? (incluso cuando el lector es uno mismo).



[Fuente imagen](#)

LOS INGREDIENTES DE LAS VISUALIZACIONES EXITOSAS

(aplican principalmente a visualizaciones exploratorias)

- 2. Reader :
 - **You Are Creating This for Other People**
 - ¿Permite mi visualización una decodificación exitosa? Es mi presentación simple?
 - **Your audience is not like you.**
 - Consideraciones contextuales para el lector, cuestiones de identidad, motivación y lenguaje, es decir, conocimiento y vocabulario especializado, como jerga profesional, contexto social aprendido.
 - Contexto de uso
 - ¿Qué información necesita mi lector para tener éxito? ¿Cuántos detalles necesita?
 - ¿Cuánto tiempo tiene ella para que sea efectivo?

LOS INGREDIENTES DE LAS VISUALIZACIONES EXITOSAS

The best visualizations will reveal what is interesting about the specific data set you're working with.

- 3. Data : Algunas preguntas básicas
 - ¿Es una serie temporal?
 - ¿Una jerarquía?
 - ¿ Cuantas dimensiones tiene?
 - ¿Cuáles son los más importantes?
 - ¿Qué tipo de relaciones tienen (p. Ej., Uno a uno o varios a muchos)? ¿Qué tan variables son?
 - ¿Son categóricos los valores? ¿Discreto o continuo? ¿Lineal o no lineal
 - ¿Cómo están acotados? Cuantas categorías hay?


Fuente: Iliinsky, Steele



LOS INGREDIENTES DE LAS VISUALIZACIONES EXITOSAS


Ahora que tenemos claro el qué y el por qué vamos con el proceso que nos ayuda con el cómo

- Esto debería llevarlo 80% del camino hacia la genialidad; ese otro 20% es la chispa creativa que tendrá que proporcionar por su cuenta.
- En la visualización de datos, la regla general número uno a tener en cuenta es la siguiente: : Function first, suave second.
- Su visualización puede parecer realmente elegante, pero si no comunica la información que está codificando (y lo hace de manera eficiente), entonces es mucho ruido visual.
- Desde determinar sus objetivos, hasta seleccionar qué dimensiones de sus datos presentar y resaltar, hasta planificar e implementar una codificación exitosa



LOS INGREDIENTES DE LAS VISUALIZACIONES EXITOSAS

- Goals
 - ¿Qué necesidad de información estoy intentando satisfacer con esta visualización?
 - ¿Qué valores o dimensiones de datos son relevantes en este contexto?
 - ¿Cuál de estas dimensiones importa? importa más; y importa lo menos?
 - ¿Cuáles son las relaciones clave que deben comunicarse?
 - ¿Qué propiedades o valores harían que algunos puntos de datos individuales fueran más interesantes que el resto?
 - ¿Qué acciones podrían tomarse una vez que se satisfaga esta necesidad de información y qué valores justificarán esa acción?



LOS INGREDIENTES DE LAS VISUALIZACIONES EXITOSAS

- Goals
 - Indican valores y relaciones específicos que la visualización debe poner a disposición del lector.
 - Este nivel de especificidad guiará directamente el proceso de diseño en una dirección particular, indicando qué dimensiones de datos deben incluirse, cómo deben relacionarse entre sí y por qué. Hablan sobre qué conocimiento se muestra, pero no cómo está estructurado.
- Encodigns sencillos de decodificar y selección de dimensiones a mostrar




Figure 3-1. Readers have a finite amount of brainpower to apply to your visualization. Any resource used on decoding depletes what is available for understanding.

SPECIFIC GRAPHS, LAYOUTS, AND AXIS STYLES

¿ Qué quiero mostrar? ¿ Para qué tipo de dato?

Bars

Histogramas

Line graphs

Time series

Pie graphs

Scatter plots

Tables

Tree maps




Figure 5-7. Good pie graphs, with few wedges and low need for precision.




Figure 5-8. Circular areas used to represent and compare quantities per region on a map.




Figure 5-6. Wind roses show frequency and speed of wind by direction.

MOTIVACIÓN


Length or height



Position



Area




Angle/area



Line weight



Hue and shade



Figures represented
in all these graphics:
22%, 25%, 34%, 29%, 32%

Visual encoding

El estilo y la estructura de una visualización dependen del propósito!

SPECIFIC GRAPHS, LAYOUTS, AND AXIS STYLES



Fuente:Alberto Cairo

<https://datavizcatalogue.com/>

<https://depictdatastudio.com/charts/>


SPECIFIC GRAPHS, LAYOUTS, AND AXIS STYLES



Fuente:Alberto Cairo


<https://ft-interactive.github.io/visual-vocabulary/>

ENCODING HIERARCHY




¿ [What do you want to show?](#)

ENCODING HIERARCHY



Inspired by Cleveland and McGill (1984)


MOTIVACIÓN



Graphics based on length, height, and position along common axes:
Great for accurate estimates


El estilo y la estructura de una visualización dependen del propósito!

ENCODING HIERARCHY



Inspired by Cleveland and McGill (1984)

MOTIVACIÓN



Other methods of encoding (size, area, color, etc.): Great for the big picture, but not so much for accuracy

El estilo y la estructura de una visualización dependen del propósito!

MINI EJERCICIO

storytelling  data[®]
WITH

community  BETA

- [Which graph would you choose?](#)
- Nos dividimos en grupos en las break-out rooms de zoom para resolver el caso.
- 15 minutos para debatirlo en grupos y hacemos revisión
- ¿Quieren hacer summit y comparar sus soluciones con las de la comunidad?



MINI EJERCICIO

storytelling  data[®]
WITH

community  BETA

- [Go one level deeper](#)
- Nos dividimos en grupos en las break-out rooms de zoom para resolver el caso.
- 15 minutos para debatirlo en grupos y hacemos revisión
- ¿Quieren hacer summit y comparar sus soluciones con las de la comunidad?



ELIGIENDO ENCONDINGS

- Una vez que conozca la "forma" de sus datos, puede codificar sus diversas dimensiones con las propiedades visuales adecuadas.
- Dos factores clave son si una propiedad visual tiene:
 - Natural ordering
 - cuántos valores distintos de esta propiedad el lector puede diferenciar fácilmente





Figure 4-1. A rainbow encoding leads to a map that is very difficult to understand. Does red mean the Alps are hotter than the rest of Europe?

ELIGIENDO ENCODINGS

- Natural ordering
 - está determinada por si la mecánica de nuestro sistema visual y el "software" en nuestro cerebro automáticamente - sin querer - asignan un orden, o clasificación, a diferentes valores de esa propiedad. Por ejemplo, la posición tiene un orden natural; la forma no lo hace. La longitud tiene un orden natural; la textura no (pero la densidad del patrón sí). El grosor o peso de la línea tiene un orden natural; el estilo de línea (sólido, punteado, discontinuo) no lo tiene.
 - El color no está ordenado. El color (matiz) no está ordenado de forma natural en nuestro cerebro. El brillo (luminosidad o luminancia, a veces llamado tinte) y la intensidad (saturación) están ordenados, pero el color en sí no lo está.




[ColorBrewer: Color Advice for Maps](https://colorbrewer2.org/)

ELIGIENDO ENCONDINGS

Elevation Zones

Europe



Digital elevation data (meters above mean sea level) were obtained as a 1 kilometer resolution elevation/bathymetry raster product from ISciences, L.L.C. Elevation zones were created by aggregating ranges of land elevation values into 12 thematic elevation classes. The 2004 ISciences data were resampled from their native 30 arc-second resolution to match GPW's population and land area 2.5 arc-minute spatial footprint. Source: ISciences, L.L.C. 300 N. Fifth Ave. Suite 120., Ann Arbor, MI 48104 <http://www.isciences.com/>.

Elevation	
< 5 m	200 - 399.9 m
5 - 9.9 m	400 - 799.9 m
10 - 24.9 m	800 - 1499.9 m
25 - 49.9 m	1500 - 2999.9 m
50 - 99.9 m	3000 - 4999.9 m
100 - 199.9 m	>= 5000 m



Copyright 2007, The Trustees of Columbia University in the City of New York. Source: Center for International Earth Science Information Network (CIESIN), Columbia University. Population, Landscape, and Climate Estimates (PLACE). Further information available at: <http://sedac.ciesin.columbia.edu/PLACE/>

Publication Date: 03/13/07



This document is licensed under a Creative Commons 2.5 Attribution License <http://creativecommons.org/licenses/by/2.5/>


ELIGIENDO ENCONDINGS

- Valores distintos
 - el lector podrá percibir, diferenciar y posiblemente recordar. Al elegir una propiedad visual, seleccione una que tenga varios valores diferenciables útiles y un ordering similar al de sus datos
- Ejemplo color versus formas

Example	Encoding	Ordered	Useful values	Quantitative	Ordinal	Categorical	Relational
	position, placement	yes	infinite	Good	Good	Good	Good
1, 2, 3; A, B, C	text labels	optional alpha or num	infinite	Good	Good	Good	Good
	length	yes	many	Good	Good		
	size, area	yes	many	Good	Good		
	angle	yes	medium	Good	Good		
	pattern density	yes	few	Good	Good		
	weight, boldness	yes	few		Good		
	saturation, brightness	yes	few		Good		
	color	no	few (<20)			Good	
	shape, icon	no	medium			Good	
	pattern texture	no	medium			Good	
	enclosure, connection	no	infinite			Good	Good
	line pattern	no	few				Good
	line endings	no	few				Good
	line weight	yes	few		Good		

Figure 4-3. Use this table of common visual properties to help you select an appropriate encoding for your data type.


ELIGIENDO ENCONDINGS



Posición, placement y texto pueden usarse para codificar cualquier tipo de data.



ELIGIENDO ENCONDINGS



¿ Por qué puede ser buena la redundancia en los encondings?

Figure 4-5. Color redundantly encodes the position of groups of companies in this graph.

ELIGIENDO ENCONDINGS




Figure 4-8. Representation of browser capabilities.

Browser	Existing color	Better color
		
		
		
		
		

No olvidemos la compatibilidad con la realidad!

ELIGIENDO ENCONDINGS

- Eligiendo la estructura
- La estructura de una visualización debería revelar algo sobre los datos subyacentes.
- ¿Qué estructura nos revela la tabla periódica?

Periodic Table of Elements

1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18

1 H Atomic #
Symbol
Name
Atomic Mass

2 He

3 Li 4 Be

5 B 6 C 7 N 8 O 9 F 10 Ne

11 Na 12 Mg

13 Al 14 Si 15 P 16 S 17 Cl 18 Ar

19 K 20 Ca 21 Sc 22 Ti 23 V 24 Cr 25 Mn 26 Fe 27 Co 28 Ni 29 Cu 30 Zn 31 Ga 32 Ge 33 As 34 Se 35 Br 36 Kr

37 Rb 38 Sr 39 Y 40 Zr 41 Nb 42 Mo 43 Tc 44 Ru 45 Rh 46 Pd 47 Ag 48 Cd 49 In 50 Sn 51 Sb 52 Te 53 I 54 Xe

55 Cs 56 Ba 57-71 72 Hf 73 Ta 74 W 75 Re 76 Os 77 Ir 78 Pt 79 Au 80 Hg 81 Tl 82 Pb 83 Bi 84 Po 85 At 86 Rn

87 Fr 88 Ra 89-103 104 Rf 105 Db 106 Sg 107 Bh 108 Hs 109 Mt 110 Ds 111 Rg 112 Uub 113 Uut 114 Uuq 115 Uup 116 Uuh 117 Uus 118 Uuo

For elements with no stable isotopes, the mass number of the isotope with the longest half-life is in parentheses.

Periodic Table Design and Interface Copyright © 1997 Michael Dayah. <http://www.ptable.com/> Last updated: May 27, 2008

57 La 58 Ce 59 Pr 60 Nd 61 Pm 62 Sm 63 Eu 64 Gd 65 Tb 66 Dy 67 Ho 68 Er 69 Tm 70 Yb 71 Lu

89 Ac 90 Th 91 Pa 92 U 93 Np 94 Pu 95 Am 96 Cm 97 Bk 98 Cf 99 Es 100 Fm 101 Md 102 No 103 Lr

Michael Dayah For a fully interactive experience, visit www.ptable.com. michael@dayah.com

Figure 4-10. This rendition of the classic table makes good use of color and line.

ELIGIENDO ENCONDINGS

- Eligiendo la estructura
 - Si queremos permitir comparaciones debemos tener cuidado con los ejes, ubicación,





Figure 4-11. The same data appears flatter (top) or steeper (bottom) depending on the scales chosen. If we were attempting to compare these data sets, the unequal axes would introduce distortion that made comparison more difficult.

ELIGIENDO ENCONDINGS

- Eligiendo la estructura
- Algunas estructuras no deben usarse nunca!

Axiis Tech Demo: Visualizing Historic Browser Statistics

By MICHAEL | *Published:* OCTOBER 31, 2009




[Fuente
imagen](#)

Fuente: Iliinsky, Steele

ELIGIENDO ENCONDINGS

- Eligiendo la estructura



ELIGIENDO ENCONDINGS

- Eligiendo la estructura
- Algunas estructuras no deben usarse nunca!




Figure 4-12. Nightingale's Rose.





Figure 4-13. A radial layout distorts the data and renders this disk usage map totally ineffective for all but the coarsest comparisons.

ELIGIENDO ENCONDINGS

- Eligiendo la estructura
- Keep it simple!



ELIGIENDO ENCONDINGS

- Eligiendo la estructura
- Keep it simple!





Figure 4-15. Palmer's representation of the same healthcare plan doesn't oversimplify, but is much easier to parse.

Fuente: Iliinsky, Steele

¿QUÉ TAN IMPORTANTE RELATIVAMENTE ES EL COLOR VERSUS POSICIÓN, ETC?



Graphical Perception: Theory, Experimentation, and Application to the Development of Graphical Methods

WILLIAM S. CLEVELAND and ROBERT MCGILL*

PLACE

- Principios
 - Semantic Distance and Relative Proximity




Figure 5-1. Placing the housecat closer to the tiger shows that it is semantically closer to that than to the other items, and forms the category felines.



Figure 5-2. Putting the water buffalo closer to the tiger causes your brain to think of a new category: perhaps, safari animals.

PLACE

- Principios
 - Absolute placement (top first)
 - Representation of Physical Space
 - Logical Relationships versus Physical Relationships
 - Patterns and Grouped Objects



PATTERNS OF ORGANIZATION

- relationships as possible axes or positional organizational schemes.
 - Importance
 - Causality
 - Dependence
 - Categorical (Not hierarchical)

¿Pensamos ejemplos?

<https://datavizcatalogue.com/>

APLIQUE BIEN LOS ENCONDINGS

- Color
 - el color no está ordenado naturalmente. Evite el uso de colores (matices) para cualquier tipo de clasificación u ordenación de datos.
 - Puede variar el brillo o la saturación con bastante eficacia para usos como mapas de calor e intensidad relativa.
 - El color puede ser una propiedad excelente para etiquetar datos categóricos o categorías no ordenadas con fines de diferenciación.
 - Solo asegúrese de no necesitar demasiados valores distintos si utiliza el color como propiedad visual para codificar las categorías.

1	Red	
2	Green	
3	Yellow	
4	Blue	
5	Black	
6	White	
7	Pink	
8	Cyan	
9	Gray	
10	Orange	
11	Brown	
12	Purple	

Aprovechemos las asociaciones communes del color: rojo (danger), verde (naturaleza), etc

APLIQUE BIEN LOS ENCONDINGS





Figure 6-1. A Stroop Test asks the subject to read aloud three different lines, and measures the length of time required to read each one.

APLIQUE BIEN LOS ENCONDINGS

- Color
 - Color theory
 - Hay tres variables principales cuando hablamos de color
 - hue (el nombre en la rueda de colores),
 - saturación (la pureza de un color)
 - brillo (qué tan claro u oscuro es el color).



HUE: (TONO)



SATURATION: (SATURACIÓN)



BRIGHTNESS: (BRILLO)



APLIQUE BIEN LOS ENCONDINGS

- Size
 - El tamaño se puede utilizar con gran ventaja para representar la importancia relativa de las entidades. Incluso si su entidad más grande es del mismo tamaño que otras "en la realidad", hacerla más grande en su visualización la hace más llamativa e indica que es más digna de atención.
 - Transmitir el tamaño relativo (o proporción) con precisión puede ser un desafío, especialmente para elementos muy grandes (por ejemplo, planetas) o muy pequeños (por ejemplo, virus).



[Fuente imagen](#)

APLIQUE BIEN LOS ENCONDINGS

- Size
 - Somos muy buenos comparando las áreas de superficie de los rectángulos en situaciones en las que la única diferencia entre ellos es la longitud.
 - Pero si movemos dos dimensiones...




Figure 6-5. Squares and rectangles of varying edge length and volume.

APLIQUE BIEN LOS ENCONDINGS

- Size
 - Una vez que va más allá de las formas geométricas regulares hacia áreas de superficie irregulares, todas las capacidades de comparación de áreas de superficie prácticamente desaparecen por la ventana.





Figure 6-6. Comparing irregular surface areas, even within recognizable shapes, is not something our brains are very good at.

APLIQUE BIEN LOS ENCONDINGS



Fuente: Alberto Cairo

APLIQUE BIEN LOS ENCONDINGS

- Texto y tipografía
 - Use Text Sparingly
 - El texto es una señal importante que le dice al cerebro de su lector cómo moverse a través de su visualización; si hay palabras y números en todas partes, el lector no sabrá por dónde empezar, o puede saltar de un lado a otro tratando de asimilar todo lo que ha escrito.
 - Fonts and Hierarchies
 - many people feel serif fonts (fonts with ornamental shapes at the ends of letters, such as Times, Cambria, or Garamond) are better for setting blocks of text, while sans serif fonts (fonts with clean line endings, such as Helvetica, Arial, or Verdana) are better for titles, tags, and labels. Evitemos Comin Sans!
 - el patrón indica el significado: no cambie las fuentes a menos que esté tratando de llamar la atención del lector sobre un cambio en el significado o la categoría del texto



APLIQUE BIEN LOS ENCONDINGS

- Texto y tipografía

It deosn't mtt aer waht oredr the ltteers in a wrod are, the olny iprmoetnt tihng is taht the frist and lsat ltteres are at the rghit pclae. The rset can be a tatol mses and you can sitll raed it wouthit a porbelm. Tihs is bcuseae we do not raed ervey lteter by it slef but the wrod as a wlohe.


Figure 6-7. The central letters within each word have been jumbled, but the text is still legible.

IT DEOSN'T MTTAER WAHT OREDR THE LTTEERS IN A WROD ARE, THE OLNLY IPRMOETNT TIHNG IS TAHT THE FRIST AND LSAT LTTERES ARE AT THE RGHIT PCLAE. THE RSET CAN BE A TATOL MSES AND YOU CAN SITLL RAED IT WOUTHIT A PORBELM. TIHS IS BCUSEAE WE DO NOT RAED ERVEY LTETER BY IT SLEF BUT THE WROD AS A WLOHE.

Figure 6-8. When the same text is written in all caps, your brain requires more time to process and understand each word.

APLIQUE BIEN LOS ENCONDINGS

- Texto y tipografía



Fuente: Alberto Cairo

<https://www.nytimes.com/interactive/2017/08/07/opinion/leonhardt-income-inequality.html>

APLIQUE BIEN LOS ENCONDINGS

- Shape
 - La forma es una propiedad muy útil para etiquetar o codificar categorías. Debido a la gran variedad de formas disponibles y la facilidad general para diferenciarlas, la forma puede ser mucho más evocadora que algunas otras propiedades.
 - Cultural Connotations
 - Illusions




Figure 6-9. Notice how the shapes appear to take on an ordering and respective depth based on how they overlap.

APLIQUE BIEN LOS ENCONDINGS

- Lines
 - Permiten representar todo tipo de relaciones. factores cualitativos, al igual que cantidad o volume o flujo




Figure 6-10. Examples of lines differentiated by: A) color; B) weight; C) endings; D) pattern; E) path; F) taper.

APLIQUE BIEN LOS ENCONDINGS

- Lines
 - A veces, las líneas que omite son tan importantes como las que incluye.




Fuente: Iliinsky, Steele

[Aaron Koblin's Flight Patterns project](#) . Qué líneas se omiten?






APLIQUE BIEN LOS ENCONDINGS

- Keys versus Direct Labeling of Data Points



MOTIVACIÓN

¿Efectivos?



Fuente: Cole Nussbaumer

MINI EJERCICIO

- [declutter!](#)
- Nos dividimos en grupos en las break-out rooms de zoom para resolver el caso.
- 15 minutos para debatirlo en grupos y hacemos revisión
- ¿Quieren hacer summit y comparar sus soluciones con las de la comunidad?

storytelling  WITH data®

community  BETA



Anexo


Pitfalls to Avoid

.



APLIQUE BIEN LOS ENCONDINGS

- Trampas a evitar
 - La comunicación es el objetivo principal de la visualización de datos.
 - Cualquier elemento que obstaculice - más que ayude - al lector, entonces, necesita ser cambiado o eliminado: etiquetas y rótulos que estorban, colores que confunden o simplemente no agregan valor, escalas o ángulos incómodos.
 - Cada elemento debe tener un propósito particular hacia el objetivo de comunicar y explicar información.
 - **La eficiencia importa, porque si estás perdiendo el tiempo o la energía de un espectador, este seguirá adelante sin recibir tu mensaje. Más adelante retomaremos story telling!**



[Fuente imagen](#)

APLIQUE BIEN LOS ENCONDINGS

- Trampas a evitar
 - Ejemplos
 - 3D (cuando son innecesarios)



APLIQUE BIEN LOS ENCONDINGS

- Trampas a evitar
 - Ejemplos
 - Gradients





Figure 6-12. Which is the “bump” and which is the “hole”? Turn the image upside down to see them swap.

APLIQUE BIEN LOS ENCONDINGS

- Trampas a evitar

- Ejemplos

- Pies



Fuente: Iliinsky, Steele

[Fuente imagen](#)

Anexo

Glosario



GLOSARIO

Chart: Something that shows qualitative information (e.g., flow charts).

Data dimensions: One single channel of data. A stock graph may comprise four properties: date, price, company, and market cap. Each is a unique dimension of the data, which can be encoded separately, with a different visual property.

Data visualization: Visualizations that are algorithmically generated and can be easily regenerated with different data, are usually data-rich, and are often aesthetically shallow.

Designer: The creator of a visualization; any reader of this book.

GLOSARIO

Encoding: The visual property (noun) applied to a dimension of data that *encodes* (verb) the information into a visual medium for decoding by the reader's brain.

Explanatory visualization: Data visualizations that are used to transmit information or a point of view from the designer to the reader. Explanatory visualizations typically have a specific "story" or information that they are intended to transmit.

Exploratory visualization: Data visualizations that are used by the designer for self-informative purposes to discover patterns, trends, or sub-problems in a dataset. Exploratory visualizations typically don't have an already-known story.

Graph: Something that shows quantitative information (e.g., pie graphs and bar graphs).

Infographic: Visualizations that are manually generated around specific data, tend to be data-shallow, and are often aesthetically rich.

GLOSARIO

Reader: The consumer of a visualization, often someone other than the designer. The reader has information needs that are meant to be satisfied by the visualization.

Visual property: A characteristic that you can see. Color, size, location, thickness, and line weight are all visual properties.




Variability of a property or data dimension: Within a visual property or single data dimension, what values are present or allowed, and how they change. Integers vary discretely; position can vary continuously. Categories are finite (and discrete, though maybe hierarchical); numbers are infinite.

Anexo



Libros Data Viz



INSPIRACIÓN...



INSPIRACIÓN ...




OUTPUTS DE ANALÍTICA

- Dashboards y [scorecards](#)...

- Interfaz simple para “un vistazo” a los datos

- Resumen de KPIs



[Fuente imagen](#)

DESIGN PATTERNS

A **design pattern** is the re-usable form of a solution to a design problem.

Dashboard Design Cheatsheet <https://dashboarddesignpatterns.github.io>

1/ Data

Detailed Data Aggregated Filtered Thresholds Derived values Single value

More Data ← Less Data

2/ Structure

Single Page Parallel Hierarchic Open

3/ Visual Representation

List Table Detailed Visualization Miniature Chart Progress Bars Gauges Indicators Trend arrow(s) Pictogram Numbers

More Detail ← Less Detail

4/ Page Layout

Open Table Stratified Grouped Schematic

5/ Screenspace

Screenfit Overflow Detail on demand Parameterization Multiple pages

More concise ← Less concise

6/ Interaction

Exploration Navigation Personalization Filter & Focus

7/ Meta Data

Data Source Disclaimer Data Description Update Information Annotations


8/ Color

Distinct Data Encoding Semantic Emotive

[Link](https://dashboarddesignpatterns.github.io)

OUTPUTS DE ANALÍTICA

- Dashboards y [scorecards](#)...en general se hacen muchos...[Toward a Scalable Census of Dashboard Designs in the Wild: A Case Study with Tableau Public](#)
- [Bach et al \(2022\)](#) discusses different design patterns for dashboards.
- The paper's [companion website](#) has the recommended step by step guide to dashboard design
- [How to evaluate data visualizations across different levels of understanding.](#)



Inspired by Cleveland and McGill (1984)