

Ley de Benford y priorización de observaciones en auditoría de datos

Apunte de clase

Introducción a Ciencia de Datos en Finanzas

Junio 2026

1. Propósito del apunte

La ley de Benford permite introducir un primer procedimiento de auditoría de datos antes de trabajar con modelos predictivos. El interés no está en reemplazar al machine learning, sino en mostrar un enfoque simple, reproducible e interpretable para detectar patrones numéricos que merecen revisión.

El punto central es el siguiente: Benford no prueba fraude. Señala desviaciones entre la distribución observada de dígitos y una distribución esperada. Es una herramienta de selección y priorización de casos, no una regla de decisión concluyente.

Idea central

Benford no detecta fraude en forma directa. Detecta que la estructura de los números no se comporta como se esperaría bajo ciertos procesos económicos. Su valor docente está en mostrar una forma simple, reproducible e interpretable de construir alertas antes de entrenar modelos predictivos.

2. La ley de Benford

En muchos conjuntos de números reales, el primer dígito significativo no se distribuye de manera uniforme. La probabilidad esperada de que el primer dígito sea d , con $d = 1, \dots, 9$, es:

$$P(D_1 = d) = \log_{10} \left(1 + \frac{1}{d} \right). \quad (1)$$

Primer dígito	Frecuencia esperada
1	30,1 %
2	17,6 %
3	12,5 %
4	9,7 %
5	7,9 %
6	6,7 %
7	5,8 %
8	5,1 %
9	4,6 %

También puede analizarse la distribución de los primeros dos dígitos significativos. Para $n = 10, 11, \dots, 99$:

$$P(D_{12} = n) = \log_{10} \left(1 + \frac{1}{n} \right). \quad (2)$$

Por ejemplo:

$$\begin{aligned} P(10) &= \log_{10}(1,1) \approx 4,14 \%, \\ P(99) &= \log_{10}(1,0101) \approx 0,44 \%. \end{aligned}$$

La versión de dos dígitos suele ser más informativa para auditoría, porque permite detectar concentraciones anómalas en combinaciones específicas, como 49, 89 o 99.

3. Intuición

La intuición usual es proporcional. Para que un número pase de empezar con 1 a empezar con 2, debe duplicarse aproximadamente. Para pasar de empezar con 8 a empezar con 9, necesita crecer bastante menos. En procesos que crecen o se escalan de manera proporcional, los números tienden a permanecer más tiempo en rangos que empiezan con dígitos bajos.

Por ese motivo, en muchos datos económicos o financieros aparece una frecuencia alta de números que empiezan con 1, luego 2, luego 3, y así sucesivamente. Esta regularidad no es universal: depende del mecanismo que genera los datos.

4. Datos donde puede aplicarse

Benford suele ser más razonable cuando se cumplen varias de las siguientes condiciones:

- hay una cantidad suficientemente grande de observaciones;
- los valores cubren varios órdenes de magnitud;
- no hay mínimos, máximos o topes administrativos muy fuertes;
- los números surgen de procesos económicos, acumulativos o multiplicativos;
- los valores no son códigos asignados arbitrariamente.

Ejemplos donde puede ser útil	Ejemplos donde suele fallar
Montos de facturas	Edades de personas
Pagos a proveedores	Números de documento
Ventas por cliente	Códigos postales
Reclamos de seguros con montos variables	Tarifas fijas o reguladas
Salos contables heterogéneos	Notas de examen
Activos, ingresos o población	Importes definidos por topes administrativos

Si, por ejemplo, una política interna requiere aprobación especial a partir de 10.000, puede observarse una concentración de importes cercanos a 9.999. Esa concentración puede indicar

evasión del umbral, pero también puede ser consecuencia del propio diseño administrativo. Por eso el análisis de dígitos siempre requiere contexto.

Advertencia de uso

Una desviación respecto de Benford no equivale a fraude. Puede reflejar manipulación, errores, redondeos, duplicaciones, límites administrativos o simplemente que el conjunto de datos no es adecuado para aplicar Benford.

5. Benford como análisis agregado

El análisis Benford clásico no asigna, por sí mismo, una probabilidad de fraude a cada fila. Su objeto principal es agregado: compara frecuencias observadas contra frecuencias esperadas.

Un flujo básico de análisis es:

1. seleccionar una columna de montos;
2. extraer primer dígito, segundo dígito o primeros dos dígitos significativos;
3. calcular la frecuencia observada de cada grupo;
4. calcular la frecuencia esperada bajo Benford;
5. medir el desvío entre observado y esperado;
6. revisar los grupos con desvíos relevantes;
7. analizar las operaciones que pertenecen a esos grupos.

La interpretación correcta es: un grupo de dígitos aparece más o menos de lo esperado. Esa señal justifica revisar operaciones, pero no alcanza para concluir fraude.

Lectura operativa

El análisis clásico de Benford es agregado: identifica grupos de dígitos anómalos. La revisión individual aparece después, cuando se listan las operaciones que pertenecen a esos grupos.

6. Medidas de desvío

Para cada grupo de dígitos k , por ejemplo $k = 10, \dots, 99$, sea:

- N : cantidad total de observaciones;
- p_k : probabilidad esperada bajo Benford;
- $E_k = Np_k$: cantidad esperada de observaciones en el grupo k ;
- O_k : cantidad observada en el grupo k .

Una medida simple de exceso observado es:

$$O_k - E_k. \quad (3)$$

También puede usarse un desvío estandarizado aproximado:

$$z_k = \frac{O_k - E_k}{\sqrt{N p_k (1 - p_k)}}. \quad (4)$$

Valores positivos altos indican grupos sobrerrepresentados; valores negativos grandes indican grupos subrepresentados. En auditoría suelen interesar especialmente los excesos positivos, porque pueden reflejar duplicaciones, redondeos, sesgos de carga o acumulaciones cerca de límites administrativos.

Otra medida frecuente en aplicaciones de Benford es la desviación absoluta media (MAD, por sus siglas en inglés):

$$MAD = \frac{1}{K} \sum_{k=1}^K |O_k^{rel} - p_k|, \quad (5)$$

donde O_k^{rel} es la frecuencia relativa observada y K es la cantidad de grupos evaluados. El MAD resume el grado global de ajuste a Benford.

7. De grupos anómalos a observaciones a revisar

Para comparar Benford con métodos de machine learning conviene construir un ranking de observaciones. Ese ranking no debe confundirse con una etiqueta de fraude. Es una forma operativa de ordenar casos para revisión.

7.1. Criterio principal: score por exceso observado del grupo

Una opción alineada con el análisis Benford tradicional es asignar a cada observación el desvío del grupo de dígitos al que pertenece. Si una operación i pertenece al grupo d_i , entonces:

$$Score_i = z_{d_i}. \quad (6)$$

De este modo, todas las observaciones que empiezan con los mismos dos dígitos reciben el mismo score de grupo. Las operaciones ubicadas en grupos sobrerrepresentados quedan más arriba en el ranking de revisión.

Grupo	Esperado	Observado	z_k	Lectura
10	alto	normal	cercano a 0	Sin señal particular
49	medio	muy alto	positivo alto	Posible acumulación artificial
87	bajo	normal	cercano a 0	Dígito teóricamente raro, pero no sobrerrepresentado
99	bajo	muy alto	positivo alto	Posible acumulación cerca de umbrales

Este criterio responde a la pregunta: la observación pertenece a un grupo de dígitos que aparece demasiado en este dataset.

7.2. Criterio auxiliar: rareza teórica del dígito

También puede construirse un score individual a partir de la probabilidad Benford del dígito observado:

$$Score_i = -\log(P(d_i)). \quad (7)$$

Este score mide la rareza teórica del patrón de dígitos bajo Benford. Es útil como analogía con enfoques de detección de anomalías basados en baja probabilidad o alta sorpresa estadística.

Nota metodológica

El score $-\log(P(d_i))$ no debe presentarse como el procedimiento estándar de auditoría Benford. Es una transformación auxiliar para obtener un ranking por observación. La práctica Benford tradicional se apoya primero en desvíos agregados de frecuencias. El criterio basado en z_k está más cerca de esa tradición, aunque la asignación del desvío del grupo a cada fila también es una decisión operativa de priorización.

La limitación del score de rareza teórica es importante: asigna valores más altos a números que empiezan con 8 o 9 aun cuando esos grupos no estén sobrerrepresentados en el dataset. Por eso, para revisión de casos, suele ser preferible partir del exceso observado por grupo.

8. Contexto operativo

Las señales de Benford son más informativas cuando se combinan con variables de negocio. Algunos patrones relevantes son:

Importe	Aspecto a revisar
9.950	Cercanía a un límite de autorización de 10.000
49.800	Cercanía a un límite de aprobación de 50.000
99.500	Cercanía a un umbral de reporte de 100.000
4.999	Posible acumulación debajo de un corte administrativo

Una regla de priorización puede combinar: exceso Benford, cercanía a umbrales, proveedor nuevo, operación fuera de horario, cuenta contable inusual, repetición de importes y desviación respecto del historial del proveedor.

9. Comparación con machine learning

Benford y machine learning responden preguntas distintas. Benford contrasta los datos contra una distribución esperada de dígitos. Los modelos de ML, en cambio, usan múltiples variables para aprender patrones de fraude, error o rareza multivariada.

Enfoque	Qué mide o aprende	Resultado	Limitación principal
Benford	Desvío respecto de una distribución esperada de dígitos	Alerta por grupo o ranking de revisión	No incorpora contexto operativo
Reglas de negocio	Violación de condiciones definidas por expertos	Indicador 0/1 o score manual	Puede ser rígido
ML supervisado	Patrones históricos asociados a fraude/no fraude	Probabilidad estimada de fraude	Requiere etiquetas confiables
ML no supervisado	Rareza multivariada respecto del conjunto de datos	Anomaly score	Puede ser menos interpretable

La diferencia conceptual es que Benford evalúa la estructura numérica del monto, mientras que ML puede evaluar la operación completa: monto, proveedor, categoría, fecha, hora, usuario, canal, país, medio de pago y antecedentes.

Diferencia clave

Benford mira si el número es raro. Machine learning puede mirar si la operación completa es rara. Por eso Benford es una señal interpretable; ML permite combinar esa señal con contexto operativo.

10. Benford como variable en un modelo

Benford también puede integrarse a un pipeline de ciencia de datos mediante variables derivadas. Algunas opciones son:

Variable	Descripción
<code>first_digit</code>	Primer dígito significativo del monto
<code>first_two_digits</code>	Primeros dos dígitos significativos
<code>benford_prob</code>	Probabilidad esperada bajo Benford
<code>benford_surprisal</code>	Rareza teórica: $-\log(P(d_i))$
<code>benford_z_group</code>	Exceso observado del grupo de dígitos
<code>near_threshold</code>	Cercanía a un límite administrativo o de aprobación
<code>round_amount</code>	Indicador de monto redondeado
<code>amount_frequency</code>	Frecuencia exacta o aproximada del monto
<code>vendor_amount_deviation</code>	Desvío del monto respecto del historial del proveedor

Este uso permite conectar auditoría tradicional, construcción de variables y modelos predictivos. No se trata de contraponer Benford a ML, sino de mostrar cómo una señal auditable puede incorporarse como insumo de un modelo más amplio.

Uso dentro del pipeline

Benford puede funcionar como control exploratorio, como criterio de priorización o como fuente de variables para un modelo. En todos los casos, la señal debe interpretarse junto con los supuestos del dataset y el contexto de negocio.

Síntesis

- Benford evalúa si la distribución de dígitos de un conjunto de números se parece a la esperada bajo ciertos procesos naturales.
- El análisis clásico es agregado: identifica grupos de dígitos anómalos, no filas fraudulentas.
- Para priorizar observaciones puede asignarse a cada fila el desvío del grupo al que pertenece.
- El score $-\log(P(d_i))$ es una transformación auxiliar de rareza teórica; no debe confundirse con el test Benford estándar.
- Las señales de Benford deben combinarse con contexto operativo y controles de negocio.
- En un pipeline de ML, Benford puede usarse como fuente de variables interpretables.

Referencias

- Durtschi, C., Hillison, W., & Pacini, C. (2004). “The effective use of Benford’s Law to assist in detecting fraud in accounting data”. *Journal of Forensic Accounting*, 5(1), 17–34. [Registro institucional](#).
- Nigrini, M. J. (2020). *Forensic Analytics: Methods and Techniques for Forensic Accounting Investigations*, 2nd ed. Wiley. [Ficha editorial](#).
- Nigrini, M. J. (2012). *Benford’s Law: Applications for Forensic Accounting, Auditing, and Fraud Detection*. Wiley.
- Da Silva Azevedo, C. et al. (2021). “A Benford’s law based method for fraud detection using R”. *MethodsX*. [Artículo abierto](#).
- Hyndman, R. J. (2021). “Surprisals”. [Nota técnica](#). Referencia útil para la idea general de puntuar observaciones según sorpresa estadística.