

Introducción a Aplicaciones de Ciencia de Datos en Finanzas

Maestría en Finanzas 2026

Prof. Pablo Roccatagliata

Universidad Torcuato di Tella

E-mail: proccatagliata@gmail.com

La evaluación del curso será mediante el siguiente trabajo (ambas partes) domiciliario¹ grupal (hasta 3 personas). La fecha de entrega es a elección hasta las 23.59 del domingo 20 de septiembre de 2026. El lunes 10 de agosto a las 19.15 hs tendremos horas de consultas sobre las consignas propuestas. Las consignas llevan varias páginas por detalles y referencias. La idea es que puedan revisar todos los temas vistos. Además algunas secciones son optativas.

Parte I Detección de señales en estados contables

Motivación

Los estados financieros pueden cumplir sus identidades contables y, sin embargo, presentar una imagen engañosa de la situación económica de una empresa. El libro [Financial Shenanigans: How to Detect Accounting Gimmicks and Fraud in Financial Reports](#), de Howard M. Schilit, Jeremy Perler y Yoni Engelhart, denomina financial shenanigans a las acciones de la gerencia que inducen a los inversores a interpretar que los resultados, los flujos de fondos o la posición financiera son más sólidos de lo que realmente son.

Por ejemplo, una compañía podría clasificar gastos operativos como inversiones, subestimar el capital necesario para mantener sus operaciones, registrar reservas insuficientes frente al deterioro de su cartera o reducir transitoriamente su deuda al cierre del período. El dataset utilizado en este ejercicio fue construido de manera sintética a partir de patrones inspirados en los casos de WorldCom, Linn Energy, New Century Financial y Lehman Brothers analizados en el libro.

El objetivo del ejercicio no es probar la existencia de fraude. Se busca construir un sistema de diagnóstico que permita identificar empresas que requieren una revisión más profunda. Una dificultad adicional es que una empresa puede presentar malos resultados sin estar manipulando su información. Del mismo modo, una empresa con buenos resultados reportados puede estar ocultando un deterioro económico. Por lo tanto, no debe interpretarse automáticamente el mal desempeño como manipulación.

Contenido

El [dataset](#) contiene información generada de forma sintética sobre 1.000 empresas correspondientes a un único período de análisis. Cada fila representa una empresa y se incluyen cinco sectores: Energy, Financials, Technology, Industrials y Consumer.

La base contiene variables financieras reportadas, variables operativas e indicadores contruados a partir de los estados financieros. Algunas empresas atraviesan un deterioro económico y reportan correctamente.

¹ Es importante que todos los participantes de un equipo trabajen activamente en la solución del caso. Desde la dirección del MFIN nos solicitan que en caso de evaluación grupal exista una instancia de evaluación individual como una defensa por parte de algún integrante del grupo si existieran dudas al respecto.

Otras presentan una de las siguientes prácticas inspiradas en casos de Financial Shenanigans:

1. Capitalización de gastos operativos, inspirada en WorldCom.
2. Subestimación del maintenance capex, inspirada en Linn Energy.
3. Reservas insuficientes por pérdidas crediticias, inspirada en New Century Financial.
4. Reducción transitoria de deuda al cierre, inspirada en Lehman Brothers.

[Aquí una descripción de cada una de ellas.](#)

Importante. Las variables `is_manipulated` y `shenanigan_type` identifican las manipulaciones introducidas en la simulación. No deben utilizarse en las primeras etapas del ejercicio; sólo podrán emplearse al final para evaluar las señales construidas.

Todos los datos son sintéticos. Las conclusiones obtenidas no deben interpretarse como evidencia sobre ninguna empresa real.

Objetivos

1. Análisis inicial de la base

Realice una primera auditoría del dataset.

- ¿Cuál es la unidad de observación?
- ¿Existen identificadores, variables constantes o variables que no deberían ingresar en un análisis estadístico?
- ¿Existen registros duplicados?
- ¿Hay valores faltantes? Distinga entre un valor realmente ausente y una variable que no resulta aplicable a determinado sector.
- Analice las distribuciones de algunas variables financieras relevantes. Incluya al menos un análisis de asimetría, curtosis y valores extremos.

No es necesario estudiar todas las columnas. Seleccione las variables que considere más informativas y justifique su elección. Compare algunas de estas distribuciones entre sectores. ¿Sería razonable considerar anormal una empresa únicamente porque sus ratios son muy diferentes del promedio general de la base?

2. Ingeniería de variables financieras

Seleccione o construya entre 8 y 12 indicadores que permitan comparar empresas de diferente tamaño. Entre otros, puede considerar:

$$EBITDA\ margin = EBITDA / Revenue$$

$$CFO\ margin = CFO / Revenue$$

$$Capex\ intensity = Capex\ total / Revenue$$

$$Maintenance\ capex\ share = Maintenance\ capex / Capex\ total$$

$$Leverage = Debt / EBITDA$$

$$Credit-loss\ coverage = Loan-loss\ reserve / NPL$$

$$Debt-end\ ratio = Debt\ at\ the\ end\ of\ the\ period / Average\ debt$$

También puede construir indicadores adicionales. Explique:

- qué mide cada indicador;
- qué comportamiento consideraría sospechoso;
- por qué conviene utilizar ratios en lugar de trabajar solamente con montos;
- qué variables deberían estandarizarse antes de aplicar métodos basados en distancias.

A partir de las descripciones anteriores, seleccione o construya al menos un indicador relacionado con cada familia de *shenanigans*. Explique por qué el indicador podría revelar una inconsistencia económica y qué otras explicaciones legítimas podrían producir un valor similar.

3. Reducción de dimensionalidad y clustering

Aplique PCA sobre un conjunto de variables cuantitativas seleccionadas y estandarizadas.

- ¿Cuánta varianza explican los primeros componentes?
- Interprete económicamente al menos los dos primeros componentes utilizando sus ponderadores.
- ¿Los componentes parecen representar rentabilidad, intensidad de inversión, leverage, calidad crediticia u otra dimensión?
- ¿La reducción de dimensionalidad permite visualizar mejor las observaciones?

Luego realice un análisis de clustering sin utilizar las variables target.

- Elija y justifique las variables, la medida de distancia y el número de clusters.
- Describa los grupos obtenidos.
- Analice si los clusters reflejan principalmente sectores económicos o si parecen identificar perfiles financieros potencialmente sospechosos.
- Explique por qué la existencia de un cluster separado no constituye por sí sola evidencia de manipulación.

Puede utilizar otra visualización, como t-SNE, de manera complementaria. En ese caso, analice si las conclusiones son estables frente a cambios en sus parámetros y evite interpretar las distancias globales del gráfico como si fueran distancias económicas exactas.

4. Construcción de un sistema de alertas explicable

Sin utilizar inicialmente el target, construya una regla o bandera para cada familia de shenanigan. Por ejemplo:

- una señal de capitalización de gastos podría combinar margen EBITDA elevado, CFO elevado y capex anormalmente alto;
- una señal tipo Linn podría combinar bajo maintenance capex share con una brecha elevada entre distributable cash flow y free cash flow;
- una señal tipo New Century podría combinar crecimiento de NPL con caída de la cobertura;
- una señal tipo Lehman podría comparar la deuda promedio con la deuda reportada al cierre.

Las reglas pueden utilizar valores absolutos, ratios, percentiles generales, percentiles calculados dentro de cada sector o combinaciones de varias condiciones. Justifique económicamente cada regla. No optimice las reglas mirando directamente el target.

Construya luego un indicador agregado (tenga cuidado con las unidades y las ponderaciones):

$$\text{Red-flag score} = w1*Flag_1 + w2*Flag_2 + w3*Flag_3 + w4*Flag_4$$

En base a este indicador:

1. identifique las 25 empresas que deberían ser revisadas prioritariamente;
2. indique qué señal o señales presenta cada una;
3. explique por qué un sistema de reglas puede resultar útil aunque no sea un modelo de machine learning.

5. Evaluación de las alertas

Recién en esta etapa utilice `is_manipulated` y `shenanigan_type`. Compare las empresas identificadas como sospechosas con las etiquetas de la simulación.

- Presente una matriz de confusión.
- Calcule precision, recall y F1.
- Analice el resultado por tipo de shenanigan.
- ¿Qué práctica parece ser más fácil de detectar?
- ¿Cuál genera más falsos positivos o falsos negativos?

Seleccione al menos tres falsos positivos y tres falsos negativos. Analice cada caso utilizando sus indicadores financieros. En particular, evalúe si algunos falsos positivos corresponden a empresas económicamente deterioradas que reportan correctamente.

Discuta qué error considera más relevante en este contexto: investigar una empresa que finalmente reportaba correctamente o dejar sin investigar una empresa que presentaba una manipulación. No es necesario asignar todavía costos monetarios ni optimizar un umbral; ese análisis se realizará en el segundo ejercicio.

Comunicación de resultados

Prepare una slide dirigida a un comité de auditoría o de inversiones que incluya:

- el objetivo del análisis;
- las principales señales utilizadas;
- las empresas que requieren revisión prioritaria;
- los resultados de la evaluación;
- las limitaciones del método.

La presentación debe dejar claro que el sistema identifica señales de riesgo, no que prueba la existencia de fraude.

Herramientas y materiales

Se recomienda utilizar Orange para el análisis exploratorio, PCA y clustering. También pueden emplearse Excel, Power BI, Python, R u otra herramienta.

No es necesario utilizar todas las variables disponibles. La selección de variables y la justificación económica forman parte del ejercicio.

No utilice las variables con valores económicos verdaderos, el monto de manipulación inyectado ni las variables destinadas exclusivamente a la clave docente.

Entregables

- Un informe breve que responda las consignas.
- El workflow de Orange o el código utilizado.
- Una tabla con las 25 empresas priorizadas y las razones de su selección.
- Una slide ejecutiva con los principales resultados.

Referencia

Schilit, H. M., Perler, J., & Engelhart, Y. (2018). *Financial Shenanigans: How to Detect Accounting Gimmicks and Fraud in Financial Reports* (4th ed.). McGraw-Hill Education.

Parte II : detección de fraude cost sensitive


Motivación

Es importante que las compañías puedan detectar correctamente transacciones fraudulentas, en particular aquellas de alto valor. ¿Qué tipos de errores pueden cometerse al clasificar automáticamente a las transacciones según su riesgo estimado de ser fraudulentas? ¿Cómo podríamos calibrar estos costos en base a las características de cada transacción?

Contenido

El [dataset](#)² contiene información de aproximadamente 1.5 millones de ³registros de transacciones de tarjeta de crédito divididos en Train.csv y Test.csv. Recuerde usar el widget [CSV File Import](#) para importar los datos. La variable de target (isFraud) indica los casos etiquetados como fraude. El target tiene más de 99% de negativos por lo que se encuentra fuertemente desbalanceada. Además, el dataset contiene predictores cuantitativos y cualitativos. Los atributos que se encuentran en este conjunto de datos son el monto de la transacción, información de contexto, id del cliente, etc.

Una primera aproximación al estudio del fraude puede realizarse mediante los tests identificados por Mark Nigrini en base a la conocida [ley de Benford](#) (first digit test, second digit test, first two digits test, first three digits test, last two digits test). Una guía posible es el siguiente caso [Using Benford's Law to detect fraud](#) de [ACFE](#) (Association of Certified Fraud Examiners)



Fuente: [Using Benford's Law to detect fraud](#)

Por otro lado, los costos asimétricos de cada error en la predicción (dejar pasar un fraude vs cancelar una transacción no fraudulenta) los pueden calibrar en base a las consecuencias de cada clasificación.

Objetivos

- Realizar un análisis exploratorio del dataset.
 - a. Algunos gráficos pueden ayudarlo a entender mejor el problema.
 - b. ¿Es necesario realizar una reducción de dimensionalidad para alguna de estas visualizaciones?
 - c. ¿Existen outliers?
 - d. ¿Podemos encontrar clusters (sin usar el target) en los datos? Este punto es relevante porque podría ocurrir que la variable de target haya identificado como fraude solamente en algunos casos. Esto podría ocurrir porque confirmar el fraude requiere un proceso costoso

² Pueden descargarlo de Kaggle (requiere cuenta gratuita) [o de este link](#).

³ Dado el tamaño del dataset necesitamos tener ciertos cuidados. Una guía [en este link](#)

que probablemente sólo se realiza sobre algunas observaciones identificadas previamente como sospechosas.


- e. ¿Hay correlaciones entre los features? [Recuerde el VIF](#).
- f. ¿Qué observaciones identificaría como sospechosas de fraude según los tests de dígitos en base a la ley de Benford?

- Ingeniería de features.

- o ¿Necesita corregir valores faltantes?
- o ¿Encuentra valores de los features que parecen errores en los datos?
- o ¿Qué preprocesamiento necesitan las variables para los algoritmos de ensamble (bagging y random forest) que va a utilizar?
- o ¿Podríamos probar diferentes estrategias para recodificar las variables categóricas como one hot encoding y target encoding?

- La variable de target (fraude/no fraude) está relativamente desbalanceada. ¿Qué cuidados debe tener al hacer el Split en train y test?

¿Qué estrategias podría usar para rebalancear el dataset?



- Entrenamos ahora un random forest.
 - a. ¿Cuáles son los hiper parámetros en random forest?
 - b. ¿Cuáles de esos hiper parámetros pueden generar sobreajuste?
 - c. Recuerde optimizar los hiper parámetros mediante validación cruzada sobre el train set.
- Introducir una estimación de los costos de cada tipo de error en la clasificación y plantee la matriz de costos de clasificación.
 - a. Puede ser útil revisar el artículo de Correa para este punto, pero tenga en mente la simplificación que planteamos en clase.
 - b. Dadas las probabilidades pronosticadas, de fraude o no fraude, que salen del random forest para cada observación, use Solver para optimizar el umbral.
 - c. Este es el umbral tal que si la probabilidad pronosticada de fraude es menor que ese nivel se considera como no fraude mientras que si la probabilidad pronosticada es mayor se predice fraude para esa observación.
 - d. La idea es encontrar cuál debería ser ese umbral para minimizar la suma de costos de los errores. Dado un umbral y unas probabilidades se arma un vector de predicciones, cada predicción puede ser correcta o no, en caso de ser incorrecta se suma al costo económico según el tipo de error del que se trate.
 - e. En base a esta regla de detección de fraude (probabilidades del random forest+umbral)
 - ¿Cuál es el accuracy obtenido? ¿Por qué cree que pasa esto?
 - i. ¿Es este umbral otro hiper parámetro?
 - ii. Conceptualmente... ¿Cómo podría incorporar su optimización en el esquema de validación cruzada utilizado?
 - f. Podemos utilizar el widget de [feature importance](#), recuerde instalar el add-on "Explain", para calcular la importancia de los predictores vía permutation importance.

- g. Hagamos un análisis gráfico mediante [los lift and gain charts](#) en base a las predicciones obtenidas, sobre test, para el modelo y umbral seleccionado. Diseñe 1 slide para comunicar los resultados del modelo en cuanto a los accionables respecto a la estrategia de retención.
- h. Compare sus resultados en cuanto a las observaciones identificadas como sospechosas de fraude en base a tests de dígitos versus machine learning cost sensitive.

Herramientas y materiales

Se recomienda que utilicen la herramienta de programación visual Orange, pero pueden utilizar el lenguaje de programación o herramienta gráfica que deseen. Sin embargo, les recomiendo usar Solver en Excel para la optimización del umbral de crédito.

Algunos links útiles

- [Using Benford's Law to detect fraud](#)
- [Mark Nigrini sobre ley de Benford](#)
- [A novel cost-sensitive framework for customer churn predictive modeling](#)
[Alejandro Correa Bahnsen * , Djamila Aouada and Björn Ottersten](#)
- [Validación de modelos en Orange.](#)
- [Gain and lift charts](#)
- [Interpretable Machine Learning](#)

Entregables

Un breve informe analizando el problema que dé respuesta a los puntos mencionados en la sección de objetivos.

Para Parte I y Parte II

Por favor adjunten también los archivos necesarios para reproducir los resultados. El uso de herramientas de IA generativa está permitido para asistencia en redacción, debugging, organización del trabajo o generación de ideas. Sin embargo, el equipo es responsable por todos los supuestos, fórmulas, resultados y conclusiones. Debe incluirse un anexo breve indicando para qué se usó IA y cómo se verificó el output. Además, deberán incluir una breve reflexión individual o grupal sobre qué aprendieron durante el proyecto: qué aspectos entendieron mejor, qué dificultades tuvieron al modelar, qué supuestos resultaron más importantes y qué cambiarían si tuvieran más tiempo.

