



Introducción a Ciencia de Datos Aplicada a Finanzas
Trabajo Práctico - Modalidad Ejecutiva
Año 2026

Profesor: Pablo Roccatagliata

Integrantes:

- Vania Caffaratti Donalisio
- Maria Daniela Cortinovis
- Valentina Andrea Rattini

Parte I Detección de señales en estados contables

Los códigos utilizados tanto para la Parte I y II se pueden acceder en el siguiente [repositorio](#) de github, utilizado por el equipo para compartir y desarrollar el código de las consignas. Sin embargo, los archivos también se adjuntan individualmente junto con el escrito.

1. Análisis inicial de la base

Los análisis a continuación se encuentran en el archivo [eda_partel.ipynb](#). Además, se utilizó para la toma de decisiones y chequeo de la base de datos el análisis univariado ([reporte_ydata_profiling_partel.html](#)) realizado con pandas profiling, que permite ver la distribución de la base de datos de forma rápida.

¿Cuál es la unidad de observación?

Una empresa en el período FY2025.

¿Existen identificadores, variables constantes o variables que no deberían ingresar en un análisis estadístico?

Identificadores: *firm_id* y *firm_name* son únicos para cada una de las 1.000 empresas, así que no sirven como variables explicativas, sólo para identificar el caso.

Variable constante: *reporting_period*, único valor FY2025 para las 1.000 empresas, por lo que no aporta variabilidad.

¿Existen registros duplicados?

Para identificar registros duplicados en la base de 1.000 empresas, aplicamos tres verificaciones complementarias en Python (pandas), cada una con un criterio distinto de qué cuenta como duplicado:

1. **Duplicados de fila completa:** usando `df.duplicated().sum()`, comparamos cada fila contra todas las anteriores considerando las 45 columnas (incluyendo *firm_id* y *firm_name*). Resultado: 0 filas duplicadas.
2. **Duplicados de identificador:** con `df['firm_id'].duplicated().sum()`, chequeamos específicamente si algún *firm_id* se repetía, lo cual indicaría un error de carga (la misma empresa cargada dos veces). Resultado: 0 IDs repetidos sobre 1.000 valores únicos.
3. **Duplicados de contenido financiero:** con `df.drop(columns=['firm_id','firm_name']).duplicated().sum()`, quitamos los identificadores antes de comparar y miramos solo los valores financieros y operativos. Este paso es clave porque detecta un caso que los dos anteriores no pueden ver: dos empresas con ID y nombre distintos pero con exactamente los mismos números financieros (por ejemplo, una fila copiada por error y renombrada). Resultado: 0 coincidencias.

¿Hay valores faltantes? Distinga entre un valor realmente ausente y una variable que no resulta aplicable a determinado sector.

Sí, hay dos tipos distintos de "faltantes" en la base, y conviene tratarlos de forma diferente:

1. Valores que "no aplica" al sector (no son datos ausentes, son ceros/NA estructurales)

- `credit_loss_coverage_reported_x`: hay 800 celdas vacías, y coinciden con las empresas fuera de Financials. No tiene sentido medir la cobertura de pérdidas crediticias en una tecnológica o una energética, así que esto no es un dato que falte, es una variable que directamente no le corresponde a ese sector.
- De forma similar, variables como `npl_reported_mm`, `provision_reported_mm` o `loan_loss_reserve_reported_mm` no tienen celdas vacías, pero vale 0 fuera de Financials, son ceros estructurales (no aplica), no ausencias.

2. Valor realmente faltante / indeterminado (sí requiere una decisión de tratamiento)

- `dividend_coverage_dcf_x` y `dividend_coverage_fcf_x`: 5 celdas vacías cada una. No es un tema sectorial: corresponden a las 5 empresas con `dividends_mm` = 0, o sea que el ratio queda indefinido por división por cero.

Analice las distribuciones de algunas variables financieras relevantes. Incluya al menos un análisis de asimetría, curtosis y valores extremos.

No es necesario estudiar todas las columnas. Seleccione las variables que considere más informativas y justifique su elección. Compare algunas de estas distribuciones entre sectores. ¿Sería razonable considerar anormal una empresa únicamente porque sus ratios son muy diferentes del promedio general de la base?

Seleccionamos ocho ratios financieros, elegidos por dos criterios combinados.

En primer lugar, priorizamos ratios financieros por sobre montos absolutos. La mayoría de las columnas de la base están expresadas en millones y reflejan principalmente el tamaño de cada empresa, no su comportamiento financiero. Dos empresas de un mismo sector pueden diferir enormemente en escala sin que eso implique nada respecto a manipulación o desempeño. Los ratios, en cambio, permiten comparar empresas de distinto tamaño en igualdad de condiciones.

En segundo lugar, cada variable fue elegida por su vínculo con una de las cuatro familias de shenanigans descritas en la consigna:

- EBITDA margin, CFO margin, Capex intensity y CFO/EBITDA están vinculadas a la capitalización de gastos operativos (WorldCom): en conjunto permiten detectar si una ganancia contable elevada está siendo acompañada por generación de caja real, o si en cambio coincide con un salto anormal en la inversión reportada.
- Maintenance capex share y DCF–FCF gap están vinculadas a la subestimación del capex de mantenimiento (Linn Energy): permiten identificar si la empresa está mostrando más flujo de caja "libre" del que realmente puede sostener, al subestimar lo que necesita invertir solo para mantener su operación actual.
- Leverage (avg) y Debt end/avg están vinculadas a la reducción transitoria de deuda al cierre (Lehman Brothers): comparan el mismo concepto de endeudamiento en dos

momentos distintos del período, permitiendo detectar si la deuda mostrada al cierre del ejercicio es representativa del nivel real que la empresa sostuvo durante el año. No incluimos variables asociadas a la tercera familia (reservas insuficientes por pérdidas crediticias, New Century Financial) en este conjunto de ocho porque las variables relevantes para esa señal (credit_loss_coverage_reported_x, npl_growth_pct, coverage_change_pp) solo aplican al sector Financials y no son comparables ni están definidas para el resto de la base.

La Tabla 1 resume los estadísticos de forma de cada variable, calculados sobre las 1.000 empresas de la base.

Variable	Skew	Curtosis (exceso)	% outliers (IQR)	Interpretación
EBITDA margin	0,33	-0,48	0,0%	Levemente asimétrica a la derecha, más achatada que una normal, sin outliers.
CFO margin	0,32	-0,30	0,3%	Forma cercana a la normal, casi sin valores extremos.
Capex intensity	1,20	0,42	5,3%	Asimetría positiva marcada: grupo de empresas con capex muy alto vs. ingresos.
CFO / EBITDA	-2,58	13,17	3,8%	La más alejada de la normalidad: asimetría muy negativa y colas extremadamente pesadas.
Maintenance capex share	-0,25	0,32	0,6%	Casi simétrica, forma cercana a la normal.
DCF – FCF gap	1,30	5,81	6,6%	Asimetría positiva fuerte y colas pesadas; mayor % de outliers del grupo.
Leverage (avg)	0,05	-1,06	0,0%	Prácticamente simétrica y sin outliers; la más bien comportada del grupo.
Debt end / avg	-1,02	2,69	1,7%	Asimetría negativa y curtosis alta: cola de empresas con deuda de cierre muy por debajo del promedio (patrón tipo Lehman).

Tabla 1. Estadísticos de forma de las variables seleccionadas.

Dos variables se destacan por alejarse marcadamente de la normalidad: **CFO/EBITDA**, con asimetría muy negativa y curtosis excesiva de 13.17 (colas mucho más pesadas que una

distribución normal), y **Debt end/avg**, con un patrón similar aunque menos extremo. Esta forma, una masa central de valores "normales" con una cola larga de valores atípicos, es consistente con la hipótesis de que la base mezcla una mayoría de empresas con comportamiento típico y una minoría con patrones inconsistentes entre variables relacionadas, que son justamente las candidatas a revisión prioritaria.




Figura 1. Distribución general de las 8 variables seleccionadas.




Figura 2. Distribución de las 8 variables seleccionadas, por sector.

Se observa una heterogeneidad marcada entre sectores en varias de las variables analizadas. Como se ve en la Figura 2, en EBITDA margin, CFO margin, Capex intensity y Maintenance capex share las curvas de densidad de cada sector están claramente desplazadas entre sí, con relativamente poca superposición. En cambio, en CFO/EBITDA, Leverage (avg) y Debt end/avg las curvas de los cinco sectores se superponen considerablemente más, lo que indica que en esas variables el sector explica una porción menor de la dispersión total.

¿Sería razonable considerar anormal una empresa únicamente porque sus ratios son muy diferentes del promedio general de la base?

No. Comparar contra el promedio general de toda la base mezcla dos fuentes de variación que conviene separar: la variación económica normal entre sectores, propia de modelos de negocio distintos, y la variación dentro de un sector, que es la que efectivamente podría señalar manipulación o deterioro. Usar el promedio general como referencia produce dos tipos de error simultáneos: por un lado, falsos positivos sistemáticos en los sectores cuyo nivel normal ya se aleja del promedio general, por ejemplo, prácticamente toda Financials aparecería como "anormal" en margen EBITDA aunque esté operando con total normalidad para su sector; por otro lado, falsos negativos en los sectores cuyo promedio coincide con el de la base completa, donde una manipulación real podría no destacarse frente al conjunto y pasar desapercibida.

Por lo tanto, la forma adecuada de definir qué es "anormal" es normalizar cada variable dentro de su propio sector (por ejemplo, mediante z-score o percentil calculado intra-sector) antes de fijar cualquier umbral. Incluso así, un valor atípico estadístico no equivale automáticamente a una alerta económica: una empresa puede presentar ratios extremos porque atraviesa un deterioro real que reporta correctamente, sin que exista manipulación alguna. La señal más relevante no es entonces la distancia a un promedio, sectorial o general, sino la inconsistencia entre variables relacionadas que deberían moverse juntas: un EBITDA elevado sin el correspondiente respaldo en CFO, una deuda de cierre muy por debajo del promedio del período, o préstamos problemáticos crecientes sin el aumento correspondiente en la cobertura.

2. Ingeniería de variables financieras

Se realizó el cálculo de los siguientes ratios financieros con el objetivo de facilitar la comparación entre las empresas analizadas. Se utilizan ratios ya que el uso de montos absolutos podría conducir a conclusiones inconsistentes debido a las diferencias existentes en tamaño, actividad, estructura operativa y volumen de operaciones. Los ratios nos permiten evaluar el desempeño de las compañías sobre una base más homogénea y comparable.

1. EBITDA margin

Este ratio se calcula realizando EBITDA/Revenue y mide el porcentaje que representa el EBITDA sobre las ventas, es decir mide la rentabilidad operativa y la eficiencia de una empresa al mostrar qué porcentaje de los ingresos totales por ventas se convierte en ganancias después de cubrir los costos operativos, excluyendo intereses, impuestos, depreciaciones y amortizaciones.

Podría resultar sospechoso:

- un aumento considerable del margen EBITDA sin una mejora equivalente en precios, volúmenes, productividad o estructura de costos;
- un crecimiento del EBITDA mientras el flujo de caja operativo permanece estancado o disminuye;
- un margen significativamente superior al de empresas comparables;
- una mejora concentrada en el cierre del ejercicio;

- frecuentes reclasificaciones de gastos operativos como “extraordinarios”, “no recurrentes” o capitalizados.

Explicaciones legítimas

Un margen elevado también puede deberse a economías de escala, aumento de precios, reducción real de costos, cambios en el mix de productos, renegociación de contratos o recuperación de capacidad ociosa.

2. CFO margin

Para calcularlo se utiliza la fórmula CFO/ Revenue.

El margen de flujo de caja operativo mide el flujo de caja operativo como porcentaje de los ingresos por ventas. A diferencia del margen operativo, que se basa en el beneficio contable, este indicador se centra en el efectivo generado por la actividad principal, incorporando los efectos de cobranzas, pagos a proveedores, inventarios y otras variaciones del capital de trabajo, lo que resulta útil para comparar el rendimiento a lo largo del tiempo o con el de la competencia.

Comportamiento sospechoso

Serían señales de alerta:

- CFO margin persistentemente inferior al EBITDA margin;
- ventas y EBITDA crecientes acompañados por un CFO decreciente;
- mejoras extraordinarias del CFO en el último trimestre;
- reducción abrupta de cuentas por cobrar mediante factoring o securitización;
- incremento significativo de cuentas por pagar;
- clasificación como operativos de cobros que económicamente pertenecen a actividades de inversión o financiación.

El flujo operativo puede mejorar temporalmente acelerando cobranzas, demorando pagos o vendiendo cuentas por cobrar, sin que exista una mejora estructural del negocio.

Explicaciones legítimas

La diferencia puede surgir de estacionalidad, expansión de inventarios, crecimiento acelerado, modificaciones en condiciones comerciales, pagos anticipados, grandes contratos o cambios normales en el ciclo de conversión de efectivo.

3. Capex intensity

El ratio se calcula de la siguiente manera: Capex total / Revenue e indica cuánto invierte la empresa en activos de largo plazo por cada unidad monetaria de ingresos. Permite evaluar la intensidad de inversión de un negocio.

Comportamiento sospechoso

Podría ser sospechoso:

- un aumento fuerte del capex sin crecimiento posterior de capacidad, ingresos o productividad;
- capex elevado acompañado por una reducción inusual de gastos operativos;
- capitalización de costos que empresas comparables normalmente reconocen como gastos;
- proyectos que permanecen durante períodos prolongados en “obras en curso”;
- crecimiento de activos intangibles sin resultados económicos observables.

Una empresa puede aumentar artificialmente el EBITDA capitalizando costos operativos, porque el desembolso deja de registrarse inmediatamente como gasto y pasa a reconocerse como activo.

Explicaciones legítimas

El incremento del indicador puede responder a una expansión productiva, modernización tecnológica, cumplimiento regulatorio, transición energética, adquisición de instalaciones o desarrollo de nuevos productos.

4. Maintenance capex share

Este ratio permite medir qué parte de la inversión total en activos se destina a mantener la capacidad operativa actual. Se calcula de la siguiente manera: Maintenance capex / Capex total.

Podría considerarse sospechoso:

- una participación de mantenimiento extremadamente baja en una empresa con activos antiguos;
- una caída continua del maintenance capex mientras aumentan las fallas, paradas o costos de reparación;
- una clasificación sistemática del capex de mantenimiento como capex de crecimiento;
- un “free cash flow ajustado” calculado restando únicamente el maintenance capex estimado por la gerencia.

Subestimar el mantenimiento permite presentar un flujo de caja libre “normalizado” artificialmente alto.

Explicaciones legítimas

Una baja participación puede ser razonable si los activos son nuevos, si se tercerizó la producción, si hubo una renovación reciente de plantas, si el negocio es poco intensivo en capital o si existe un programa de mantenimiento especialmente eficiente.

5. Leverage

El ratio de apalancamiento se calcula realizando el cociente entre Debt y EBITDA y permite ver en cuánto tiempo (años) se cancela la deuda.

Comportamiento sospechoso

Serían señales de alerta:

- una reducción del ratio originada exclusivamente en ajustes al EBITDA;
- exclusión de deuda considerada “sin recurso”, arrendamientos, factoring con recurso o pasivos de vehículos especiales;
- utilización de deuda medida en una fecha especialmente favorable;
- incremento del EBITDA ajustado mientras la generación de caja no mejora;
- diferencias importantes entre el leverage informado por la empresa y el calculado a partir de los estados financieros.

El ratio puede manipularse tanto reduciendo artificialmente el numerador como aumentando el EBITDA mediante ajustes no recurrentes.

Explicaciones legítimas

Una baja del leverage puede deberse a cancelación genuina de deuda, crecimiento operativo, aportes de capital, venta de activos no estratégicos o una mejora temporal pero real de los resultados.

6. Credit-loss coverage

El ratio se calcula de la siguiente manera: $\text{Loan-loss reserve} / \text{NPL}$. Mide qué proporción de los créditos deteriorados o en mora está cubierta por provisiones constituidas para absorber las pérdidas esperadas.

Comportamiento sospechoso

Podría ser sospechoso:

- caída de la cobertura mientras aumentan la mora y los préstamos reestructurados;
- estabilidad artificial de los NPL a pesar del deterioro macroeconómico;
- reclasificación de préstamos morosos como refinanciados o vigentes;
- liberación de provisiones para aumentar resultados;
- cobertura muy inferior a la de entidades comparables con carteras similares.

Una entidad puede mejorar temporalmente sus ganancias constituyendo provisiones insuficientes o liberando reservas acumuladas en períodos anteriores.

Explicaciones legítimas

Una cobertura menor puede justificarse por garantías de alta calidad, recuperaciones esperadas, distinta composición de cartera, seguros de crédito, cambios regulatorios o una reducción auténtica del riesgo de los deudores.

7. Debt-end ratio

Se calcula realizando el siguiente cociente: $\text{Debt at the end of the period} / \text{Average debt}$. Compara la deuda registrada al cierre con el endeudamiento promedio mantenido durante el período. Permite detectar si la posición de cierre representa razonablemente el nivel habitual de financiamiento.

Comportamiento sospechoso

Un ratio muy inferior a 1 puede indicar que la empresa canceló deuda inmediatamente antes del cierre para presentar una posición financiera más sólida y volvió a endeudarse posteriormente.

También sería relevante observar:

- grandes entradas de efectivo pocos días antes del cierre;
- factoring o venta de activos seguida de recompra;
- préstamos cancelados antes del cierre y renovados después;
- movimientos relevantes entre partes relacionadas;
- diferencias sistemáticas entre deuda promedio y deuda de cierre.

Explicaciones legítimas

El ratio puede ser bajo por estacionalidad, cobro de clientes concentrado al cierre, vencimientos contractuales, venta definitiva de activos, emisión de capital o reducción genuina de necesidades de financiamiento.

8. Cobertura de intereses

El ratio se calcula realizando EBITDA/intereses y mide cuantas veces el beneficio operativo bruto cubre los gastos financieros por intereses. Un valor mayor a 3 indicaría una cobertura óptima mientras que un valor menor a 1 mostraría una situación crítica ya que el resultado no alcanza a cubrir los intereses.

Indicadores por familia de shenanigans

Este análisis se realizó en el excel Ejercicio_1_datos_y_etiquetas.

Para cada familia de *shenanigan* se construyó una bandera de alerta a partir de ratios financieros seleccionados por su relación económica con el tipo de manipulación analizado. Los umbrales se definieron mediante percentiles calculados dentro de cada sector, con el objetivo de comparar a cada empresa con compañías de características económicas similares y reducir el efecto de diferencias estructurales entre industrias.

A. Capitalización de gastos operativos — WorldCom

Para identificar posibles señales de capitalización indebida de gastos operativos se utilizaron los siguientes indicadores:

- ebitda_margin_pct
- cfo_margin_pct
- capex_intensity_pct

Se definieron como umbrales, dentro de cada sector:

- Percentil 75 para ebitda_margin_pct;

- Percentil 85 para cfo_margin_pct;
- Percentil 90 para capex_intensity_pct.

La primera bandera se activa cuando una empresa supera simultáneamente los tres umbrales correspondientes a su sector. La lógica económica es que, si determinados gastos operativos fueran registrados como activos en lugar de reconocerse como gasto del período, podría observarse un EBITDA artificialmente elevado, acompañado por una mayor intensidad de capex. A su vez, el flujo de caja operativo podría mostrar un nivel aparentemente sólido en relación con los resultados reportados.

Sin embargo, esta combinación podría representar una expansión genuina o adquisición de activos productivos.

B. Subestimación del maintenance capex - Linn

Para detectar posibles señales de subestimación de las inversiones necesarias para mantener la capacidad operativa se utilizaron:

- maintenance_capex_share
- la diferencia entre distributable_cash_flow y free_cash_flow.

Los umbrales se calcularon dentro de cada sector:

- Percentil 10 para maintenance_capex_share;
- Percentil 90 para la brecha entre distributable_cash_flow y free_cash_flow.

La segunda bandera se activa cuando se cumple simultáneamente maintenance capex share < P10 y distributable cash flow- free cash flow > P90.

La lógica es que una empresa podría presentar un flujo distribuible elevado si subestima el monto de inversión necesario para mantener sus activos operativos. En ese caso, se observaría una participación inusualmente baja del maintenance capex y, al mismo tiempo, una brecha elevada entre el flujo distribuible y el flujo de caja libre.

Sin embargo, esta señal también podría responder a una menor necesidad genuina de mantenimiento, activos relativamente nuevos o diferencias en la intensidad de capital entre empresas.

C. Reservas insuficientes por pérdidas crediticias - New Century Financial

Este análisis se realizó exclusivamente para empresas del sector financiero.

Los indicadores considerados fueron:

- npl_growth_pct: crecimiento de los préstamos problemáticos respecto del período anterior;
- coverage_change_pp: variación de la cobertura crediticia respecto del período anterior, expresada en puntos porcentuales;
- credit_loss_coverage_reported_x: reservas crediticias reportadas divididas por los préstamos problemáticos.

Se utilizaron los siguientes umbrales:

- Percentil 75 para `npl_growth_pct`;
- Percentil 25 para `coverage_change_pp`;
- Percentil 25 para `credit_loss_coverage_reported_x`.

La tercera bandera se activa cuando una empresa presenta simultáneamente `npl growth > P75`, `coverage change < P25` y `credit loss coverage < P25`.

La señal busca identificar situaciones en las que el deterioro de la cartera crediticia aumenta, mientras que las reservas y la cobertura reportadas no acompañan dicho deterioro.

Económicamente, esta combinación puede ser consistente con una política de provisiones insuficientes frente a un aumento del riesgo crediticio. No obstante, también podría explicarse por expectativas de recuperación, garantías de buena calidad, cambios en la composición de la cartera o diferencias en las políticas internas de provisiones.

D. Reducción transitoria de deuda al cierre - Lehman Brothers

Para identificar posibles señales de reducción transitoria de deuda al cierre se utilizó el indicador:

- `debt_end_to_avg_x`: deuda reportada al cierre dividida por la deuda promedio del período.

La bandera se construyó comparando este ratio dentro de cada sector y utilizando como umbral el percentil 5. Se consideraron sospechosas aquellas empresas con valores excepcionalmente bajos del indicador, ya que esto implica que la deuda reportada al cierre resulta considerablemente inferior al nivel promedio mantenido durante el período.

La lógica económica es que una empresa que reduzca temporalmente su deuda antes de la fecha de cierre podría presentar una posición de apalancamiento más favorable que la que sostuvo a lo largo del período.

Estandarización de variables

Antes de aplicar métodos basados en distancias, deben estandarizarse todas las variables cuantitativas seleccionadas, especialmente los montos y ratios que presentan escalas diferentes. En nuestro caso, este procedimiento fue realizado internamente por FAMD en las secciones siguientes.

3. Reducción de dimensionalidad y clustering

El análisis de esta sección se encuentra en la jupyter notebook llamada [pca_y_clustering.ipynb](#)

La primera tarea fue realizar una selección de variables, intentando de que tengan sentido económico, que no estén tan correlacionadas entre sí, y que reflejan las anomalías que pueden terminar determinando si una de las empresas tiene fraude en sus estados contables.

Variables Incluidas de la BD	Notas
sector	Al incluirla como variable categórica, no podemos usar un PCA normal.
revenue_reported_mm, revenue_growth_pct, ebitda_reported_mm, ebitda_margin_change_pp, cfo_reported_mm, net_income_reported_mm, ebitda_margin_pct, cfo_margin_pct, dcf_fcf_gap_mm,	Resultados y generación de caja
interest_expense_reported_mm, cash_taxes_reported_mm, debt_avg_mm, debt_end_reported_mm, debt_end_to_avg_x, cfo_to_ebitda_reported_x,	Deuda y taxes
capex_total_reported_mm, capex_growth_pct, capex_intensity_pct, maintenance_capex_share_pct,	Capex
dividends_mm,	Dividendos
total_assets_reported_mm, cash_reported_mm, accounts_receivable_reported_mm, inventory_reported_mm, assets_to_revenue_x,	Activos


Variables construidas	Notas
interest/EBITDA	$\text{df['interest_expense_reported_mm']} / \text{df['ebitda_reported_mm']}$
ebitda_adjustment_pct	$(\text{df['adjusted_ebitda_reported_mm']} - \text{df['ebitda_reported_mm']}) / \text{df['ebitda_reported_mm'].abs()}$

Variables no incluidas	Notas
firm_id	Irrelevante
firm_name	Irrelevante
reporting_period	Constante

dividend_coverage_dcf_x, dividend_coverage_fcf_x	No se encuentran definidos para las empresas que no distribuyen dividendos y presentan valores extremos cuando el monto de dividendos es muy reducido
npl_growth_pct, coverage_change_pp, credit_loss_coverage_reported_x, provision_reported_mm, loan_loss_reserve_reported_mm, npl_reported_mm	Solo de Financials
leverage_reported_x, operating_expenses_reported_mm, fcf_reported_mm, leverage_avg_x, adjusted_ebitda_reported_mm, maintenance_capex_reported_mm, growth_capex_reported_mm, distributable_cash_flow_reported_mm	Muy correlacionadas con las otras variables, o son el resultado directo de operaciones de otras variables

La base de datos, por su naturaleza tiene empresas de diferentes tamaños y sectores, que son difíciles de comparar entre sí. Se barajaron opciones para intentar que los análisis posteriores no describieron únicamente el tamaño y el sector sino nuestro objetivo final, que es detectar fraude contable. Para no dejar únicamente variables en ratios, y poder incluir toda la información disponible, se decidió a las variables que estaban expresadas en mm, aplicarles un logaritmo, manteniendo el signo. El signo lo mantuvimos para guardar la dirección y la interpretabilidad económica, pero aplicamos el logaritmo para que estén mejor comportadas.


Además, se decidió dejar algunas variables aunque estén muy correlacionadas, con la hipótesis que el fraude se detecte en variables que deberían ser muy similares, pero para las empresas fraudulentas no lo son, como por ejemplo debt_avg_mm y debt_end_reported_mm en las operaciones conocidas como Repo 105 de Lehman Brothers. A continuación se muestra un correlograma de las variables que fueron finalmente seleccionadas.



La metodología consistió en introducir las variables en un modelo de reducción de dimensionalidad Factor Analysis of Mixed Data (FAMD)¹, que es una extensión de un PCA para datos que contienen simultáneamente variables numéricas y categóricas. El modelo internamente corre un Standard Scaler, por lo que no lo hacemos por separado. Se hicieron 31 componentes con las variables seleccionadas.

¿Cuánta varianza explican los primeros componentes?

En el gráfico se puede ver que los primeros 4 componentes explican el 66% de la varianza, mientras que el 95% de la varianza es explicada por los primeros 14.




¹ Es el mismo enfoque estadístico que un PCAmix de R, pero para python con la biblioteca de python prince.


Interprete económicamente al menos los dos primeros componentes utilizando sus ponderadores. ¿Los componentes parecen representar rentabilidad, intensidad de inversión, leverage, calidad crediticia u otra dimensión?

Analizamos los primeros 4 componentes principales, graficando cada empresa en un *pairplot*, para ver cómo interaccionan entre ellas en una matriz y además, poder interpretar si los componentes están relacionados con los sectores. El tamaño de los markers describe el tamaño de la empresa, usando *revenue_reported_mm* como proxy de tamaño.

Mirando el *pairplot*, se observa que, al haber incluido la variable sector en el PCA, las componentes diferencian a los sectores, PC2 separa al sector de Financials y PC4 al sector Energy. La separación no es perfecta, pero está presente en los componentes, a pesar de no ser el objetivo final de este ejercicio. Se observa además, que los componentes también describen el tamaño de las empresas, donde PC1 y PC2 están relacionadas inversamente con el tamaño de la empresa.




La separación por sectores también se puede observar en el siguiente heatmap, donde vemos la media de los 4 componentes principales, abierto por los 5 sectores.



A continuación dejamos un heatmap con los pesos del PCA para cada una de las variables que en donde se ordena las variables según su peso dentro de ese componente, así se distinguen tanto la magnitud como la dirección positiva o negativa.



Se observa que los componentes tienen pesos muy diferentes para cada una de las variables. Para poder observarlo mejor mostramos para los primeros 4 componentes los pesos ordenados de mayor a menor, manteniendo los signos.



Analizamos en detalle los primeros cuatro componentes:

- **PC1:** El primer componente explica el 32% de la variabilidad total, y se puede interpretar que está relacionada de forma inversa con el tamaño y la escala económica de la empresa. Los pesos negativos más grandes están asociados a variables en mm, como EBITDA, CFO y cash taxes reported, net income, variables en mm que reflejan a empresas más grandes. En los pesos positivos se observa a ebitda_adjustment_pct y dcf_fcf_gap_mm que pueden reflejar empresas más pequeñas o empresas en las que los ajustes sobre el EBITDA y las diferencias entre medidas de flujo tienen mayor peso relativo. PC1 parece estar asociada positivamente con pertenecer al sector consumer e industriales.
- **PC2:** El segundo componente explica el 16% de la variabilidad, y se puede ver que separa al sector financieros y energía, en el pairplot. Está relacionado positivamente con pertenecer al sector financieros, y tener altos márgenes (cfo_margin_pct, ebitda_margin_pct), buena conversión de ebitda en flujo de caja (cfo_to_ebitda_reported_x) y una alta relación de activos y revenue (assets_to_revenue_x). Está relacionado inversamente con empresas con altos

montos e intensidad de capex (`capex_total_reported_mm`, `capex_intensity_pct`), inventario (`inventory_reported_mm`) y cuentas por cobrar reportadas (`accounts_receivable_reported_mm`).

Es decir, divide la forma en que la empresa genera resultados y utiliza sus recursos, que también por lo tanto separa a las empresas de financieros de las de industria y energía.

- **PC3:** Explica el 10% de la variabilidad total, y está relacionada positivamente con mayor carga de intereses sobre EBITDA (`interest/EBITDA`), y mayor cantidad de assets (`assets_to_revenue_x`, `total_assets_reported_mm`) y cash (`cash_reported_mm`), es decir empresas con estructuras patrimoniales grandes, e intensivas en activos, y negativamente con empresas caracterizadas por mucho crecimiento (`revenue_growth_pct`, `ebitda_margin_change_pp`, `capex_growth_pct`) y desempeño operativo (`cfo_to_ebitda_reported_x`), como empresas de tecnología (`sector_Technology`).

A diferencia de los otros componentes, no parece estar tan relacionada con el tamaño.

- **PC4:** La componente 4 explica únicamente el 4% de la variabilidad total. Está relacionada positivamente con pertenecer al sector de tecnología (`sector_Technology`), y mayor endeudamiento (`interest/EBITDA`, `interest_expense_reported_mm`, `debt_avg_mm`, `debt_end_reported_mm`), altas cuentas por cobrar (`accounts_receivable_reported_mm`) y altos revenues en valor absoluto y en crecimiento (`revenue_reported_mm`, `revenue_growth_pct`). Está relacionada negativamente con pertenecer al sector de energía (`sector_Energy`), tener alto capex y ser empresas intensivas en activos físicos e inversión (`capex_intensity_pct`, `maintenance_capex_share_pct`, `assets_to_revenue_x`). Por lo tanto, PC4 diferencia principalmente empresas tecnológicas con mayor peso de cuentas por cobrar y financiamiento frente a empresas energéticas e intensivas en activos y capex.

¿La reducción de dimensionalidad permite visualizar mejor las observaciones?

Sí, como vimos en los gráficos del punto anterior, con las primeras 4 componentes se puede explicar el 66% de la varianza de las variables, y se puede graficar en diagramas 2D de forma sencilla.


Análisis de Clustering

Elija y justifique las variables, la medida de distancia y el número de clusters.


Para realizar el análisis de clusters, se utilizaron los 14 primeros componentes del PCA, que describen el 95% de la varianza. Se probaron 3 algoritmos de clustering diferentes: K-Means, GMM y HDBSCAN.

- Selección de K para Kmeans

Como primera tarea, se seleccionó el número de K para el k means, para eso se probaron 7 valores de k entre 2 y 8 para seleccionar el más apropiado. Los resultados se muestran en el gráfico a continuación:




El gráfico de inercia es difícil de interpretar, no hay un código claro, pero interpretamos que el cambio de pendiente está en $k = 3$. El silhouette en cambio muestra su valor más alto en $k = 3$, Calinski-Harabasz en $k = 2$ pero seguido muy de cerca por $k = 3$ y Davies-Bouldin su valor más bajo en $k = 3$. Por lo que decidimos que el k a utilizar será $k = 3$. Graficamos a continuación, cómo quedan los grupos graficados en PC1 y PC2. Se observa que el grupo $k = 3$ está bien separado en función de PC1 y PC2. Al ser tan pocos clusters es probable que no estemos separando tan bien el fraude, sino más bien sectores.




El silhouette, una métrica que va desde -1 a +1, es igual a 0,22 un número bastante bajo. Podemos abrirlo por gráfico, como se observa en la siguiente imagen, vemos que para $k = 3$

la mayoría de los datos tienen silhouette positivo, y que los cluster tienen un tamaño razonable. La métrica parece ser menor para los clusters 2 y 1.



- Selección de parámetros HDBSCAN

HDBSCAN tiene dos parámetros, `min_cluster_size` y `min_samples`, hicimos tres mapas de calor para ver con cuántos clusters, ruido y valor de silhouette nos íbamos a quedar con cada combinación.



En función de los resultados, seleccionamos `min_cluster_size=10` y `min_samples=3`. Lo que nos da 5 clusters, un nivel no tan alto de ruido (8,6) y un silhouette de 0,22.

- Selección de distancia


Se utilizó la distancia euclídea sobre los componentes obtenidos mediante el FAMD. Esta elección se consideró adecuada porque las variables numéricas fueron estandarizadas y los componentes resultantes son ortogonales, lo que evita que las diferencias de escala y la correlación entre los indicadores distorsionen excesivamente las distancias.

Describe los grupos obtenidos.

Para armar los grupos se utilizaron 3 algoritmos diferentes: K-means, HDBSCAN y GMM. La idea fue usar a **Kmeans** como algoritmo base, es un método más sencillo y ampliamente utilizado, que tiende a encontrar clusters compactos y aproximadamente esféricos. **HDBSCAN** permitió incorporar un enfoque basado en densidad, a diferencia de K-Means, no requiere definir previamente el número de clusters, aunque sí necesita seleccionar parámetros como `min_cluster_size` y `min_samples`. Además, puede identificar grupos con formas más irregulares y clasificar como ruido aquellas observaciones que no pertenecen claramente a ningún cluster. Finalmente, **GMM** tiene la ventaja de que permite estimar la probabilidad de pertenencia de cada empresa a los distintos cluster, lo que es interesante en casos como el nuestro donde la pertenencia a clusters puede ser superpuesta.

A continuación detallamos los resultados de los tres métodos utilizados y un gráfico frente a los componentes PC1 y PC2:

Método	N clusters	Ruido (%)	Silhouette	Calinski-Harabasz	Davies-Bouldin
K-Means	3	0.0	0.219	273.119	1.578
HDBSCAN	5	8.6	0.223	194.309	1.620
GMM	3	0.0	0.219	271.122	1.553



En función de los resultados se decide seleccionar el Kmeans, principalmente porque tiene una buena relación entre las métricas, tiene un Silhouette bastante cercano al máximo, el Calinski-Harabasz más alto y el Davies-Bouldin cercano al mínimo. Sin embargo, un Silhouette de 0.219 es relativamente bajo. Esto indica que los clusters existen, pero se superponen bastante y no son grupos perfectamente separados.

El K-Means dio como resultado 3 clusters:


Cluster	N Empresas	% Consumer	% Energy	% Financials	% Industrials	% Technology
0	191	0.0	0.0	99.0	0.0	1.0
1	425	40.0	4.0	2.6	23.3	30.1
2	384	7.8	47.7	0.0	26.3	18.2

De los cuales el cluster 0 tiene 191 empresas, donde el 99% pertenece al sector Financials. El cluster 1 en cambio, tiene 425 empresas (es el cluster más grande), de las cuales, el 40% está en Consumer, y la mayor parte de las empresas restantes están en Industrials (23%) y Tecnología (30%). El cluster 2 tiene 384 empresas, de las cuales la mayoría (47%) pertenecen al sector energía, y el resto a Industrials (26%) y tecnología (18%).


Analice si los clusters reflejan principalmente sectores económicos o si parecen identificar perfiles financieros potencialmente sospechosos.

Para interpretar económicamente los clusters, agrupamos las variables en cuatro dimensiones: resultados y generación de caja, deuda e impuestos, capex y activos. Los heatmaps muestran el promedio estandarizado de cada variable dentro de cada clúster. Los valores positivos indican que el cluster se encuentra por encima del promedio general y los negativos, por debajo.


- Resultados y generación de caja




- Deuda y taxes



- Capex



- Activos



En términos generales, el cluster 0, compuesto casi completamente por empresas financieras, presenta márgenes y generación de caja superiores al promedio. El cluster 1 reúne empresas de menor escala y con resultados operativos relativamente más bajos. Por su parte, el cluster 2 contiene empresas de mayor tamaño, con mayores niveles de ingresos, EBITDA y CFO, aunque con márgenes más cercanos al promedio. Estos perfiles son consistentes con la composición sectorial observada en cada grupo.


Explique por qué la existencia de un cluster separado no constituye por sí sola evidencia de manipulación.

Porque el modelo solamente hace clusters en función de la similitud de las variables, y no utiliza la variable target, es un algoritmo no supervisado. La separación puede responder a diferencias legítimas de sector, tamaño o modelo de negocio. En consecuencia, los clusters permiten identificar perfiles distintos o casos que merecen revisión, pero no alcanzan por sí solos para concluir que hubo manipulación contable.

Visualización t-SNE

Realizamos una visualización t-SNE, que es una técnica de reducción de dimensionalidad usada para visualizar datos complejos en dos dimensiones. Probamos ver como cambiaban

los clusters en función del parámetro de perplexity, los resultados se muestran a continuación:



En colores diferentes se grafican los clusters obtenidos mediante K-Means, con el objetivo de ver si mantienen una separación reconocible con esta otra metodología. En los distintos valores de perplexity, el cluster 0 aparece claramente diferenciado, mientras que los clusters 1 y 2 presentan mayor cercanía y cierto solapamiento. Aunque cambian la forma y la ubicación de los grupos, la estructura general se mantiene para diferentes valores de perplexity. Esta visualización permite evaluar la separación entre las observaciones, pero no identificar las variables que caracterizan cada cluster, para eso utilizamos los perfiles promedio y los heatmaps en las secciones anteriores. Además, las distancias del gráfico no deben interpretarse como diferencias económicas exactas.

4. Construcción de un sistema de alertas explicable

La construcción de los flags se hizo en el excel Ejercicio_1_datos_y_etiquetas y el análisis de los resultados en [flags.ipynb](https://github.com/Flags-IPYNB).

Con los flags detallados en la sección 2, se construyó un indicador agregado. El score mide no sólo cuántas alertas activa una empresa, sino también qué tan lejos se encuentran sus indicadores de los umbrales sectoriales.

Para cada indicador se calculó un exceso relativo respecto del percentil correspondiente. Entonces una variable resulta sospechosa cuando es elevada:


$$Exceso = \max\left(0, \frac{Valor - Umbral}{Umbral}\right)$$

En las variables que resultan sospechosas cuando son bajas, se calculó la distancia en sentido contrario. De esta manera, una empresa no obtiene mayor prioridad solo por activar una regla, sino también por la magnitud de la anomalía observada. Luego, para cada flag, se promediaron los excesos de los indicadores que la componen. Finalmente, el score se obtuvo sumando las intensidades de las flags activadas:

$$Score = Flag_1 I_1 + Flag_2 I_2 + Flag_3 I_3 + Flag_4 I_4$$

donde I_j representa la intensidad de cada alerta.

A continuación se observa la distribución del score:



Las empresas se ordenaron de mayor a menor según este score y se seleccionaron las 25 observaciones con mayor nivel de alerta para revisión prioritaria:

Selección de las 25 empresas prioritarias y señales activadas


El score al ser una variable continua nos permite identificar las empresas, con él seleccionamos las 25 empresas más sospechosas.

firm_id	sector	Score	Señales activadas
F0968	Consumer	0.967	Linn
F0210	Financials	0.956	New Century
F0316	Financials	0.671	New Century
F0338	Financials	0.644	New Century
F0232	Financials	0.639	New Century
F0022	Energy	0.633	Linn
F0367	Financials	0.577	New Century
F0857	Consumer	0.531	Linn
F0237	Financials	0.517	WorldCom
F0076	Energy	0.514	Linn
F0351	Financials	0.474	New Century
F0255	Financials	0.473	New Century
F0298	Financials	0.357	Linn
F0304	Financials	0.319	New Century
F0702	Industrials	0.300	Linn
F0015	Energy	0.251	Linn
F0357	Financials	0.235	WorldCom, Lehman
F0137	Energy	0.221	Linn
F0086	Energy	0.211	Lehman
F0647	Industrials	0.192	Lehman

F0949	Consumer	0.189	WorldCom
F0666	Industrials	0.184	WorldCom
F0870	Consumer	0.184	Lehman
F0715	Industrials	0.176	Linn
F0148	Energy	0.173	WorldCom

A continuación dejamos un diagrama de torta de cómo están distribuidas las señales en las 25 empresas, se ve que la mayoría tienen el flag Linn Energy (35%) representando a 9 empresas y el Flag New Century (31%) con 8 empresas. Hay 26 señales activadas entre 25 empresas, porque la empresa F0357 activa dos flags.

Señales activadas en las 25 empresas seleccionadas



Explique por qué un sistema de reglas puede resultar útil aunque no sea un modelo de machine learning.

Porque es interpretable, sencillo y fácil de implementar, el negocio no solo necesita predecir sino también comprender a qué se debe el flag. Puede ser complementario a un modelo de machine learning, o utilizarse para armar grupos de interés.

5. Evaluación de las alertas

En esta sección utilizamos las etiquetas de `is_manipulated` y `shenanigan_type`. Se observó que el 12% de las 1000 observaciones están manipuladas.

Matriz de confusión

Se observa que el score que selecciona a las 25 empresas más prioritarias es capaz de identificar a 22 verdaderos positivos, tiene 3 falsos positivos, pero se le escapan 98 falsos negativos. Al tomar sólo 25 empresas, naturalmente algunos casos de fraude no van a ser identificados. Este resultado muestra que el score es útil para priorizar una cantidad reducida de empresas, aunque no permite identificar todos los casos.

Matriz de confusión				
Modelo	TP	FN	FP	TN
Score 25	22	98	3	877

Métricas de precision, recall y F1

El sistema alcanza una precisión del 88%, ya que 22 de las 25 empresas seleccionadas estaban manipuladas. El recall es del 18,3%, porque identifica 22 de las 120 empresas manipuladas de la base. El F1 es del 30,3%, como resultado de combinar una precisión alta con un recall bajo.

Modelo	precision	recall	f1
Score 25	88.0%	18.3%	30.3%

Analice el resultado por tipo de shenanigan. ¿Qué práctica parece ser más fácil de detectar? ¿Cuál genera más falsos positivos o falsos negativos?

Al analizar los resultados por tipo, la señal New Century es la que presenta el mejor desempeño: identifica 8 casos y no genera falsos positivos. Por eso alcanza una precisión del 100% y el F1 más alto. La señal Linn es la que genera más falsos positivos, con 5 casos. Por su parte, WorldCom y Lehman presentan la mayor cantidad de falsos negativos, con 27 cada una. En general, el recall es bajo para todas las categorías porque el análisis se limita a las 25 empresas consideradas prioritarias.

Shenanigan	TP	FP	FN	Precision	Recall	F1
WorldCom	3	2	27	60.0%	10.0%	17.1%
Linn	4	5	26	44.4%	13.3%	20.5%
New Century	8	0	22	100.0%	26.7%	42.1%
Lehman	3	1	27	75.0%	10.0%	17.6%

La práctica más fácil de detectar con el score utilizado parece ser la subestimación de reservas crediticias asociada a New Century, ya que presenta el F1 más alto y no genera falsos positivos. Dentro de las 25 empresas seleccionadas, la regla identifica 8 de los 30 casos reales.

Análisis tres falsos positivos

Seleccionamos las 3 empresas con **mayor score** que tenían falsos positivos, es decir que son marcadas como sospechosas pero no fueron etiquetadas como manipuladas. Vemos que 2 tienen Flag WorldCom y una Flag Linn energy.

firm_id	sector	Score	Flag WorldCom	Flag Linn energy	Flag New Century	Flag Lehman
---------	--------	-------	---------------	------------------	------------------	-------------


F0666	Industrials	0.184194	1	0	0	0
F0715	Industrials	0.176121	0	1	0	0
F0148	Energy	0.173467	1	0	0	0

Analizamos cada caso por separado, observando el heatmap a continuación que muestra ciertas métricas, donde el valor cero representa la mediana sectorial, los valores positivos y negativos indican cuántos desvíos estándar se encuentra cada empresa por encima o por debajo de la mediana.

Se identifica que los falsos positivos no muestran un patrón común de deterioro:

- *F0666* y *F0148*, que fueron marcadas con el flag de WorldCom, es decir el shenanigan de posible capitalización de gastos operativos, donde para armar el score se identificó a las empresas con percentil 75 para *ebitda_margin_pct*, percentil 85 para *cfo_margin_pct* y percentil 90 para *capex_intensity_pct*. Estas empresas presentan indicadores financieros sólidos y parecen haber sido seleccionadas por mostrar valores excepcionalmente altos.
- *F0715*, en cambio que fue identificada con el Flag Linn energy, que indica una subestimación del maintenance capex, aumentando artificialmente el flujo distribuible respecto del FCF. El flag está asociado a empresas que están en el percentil 10 para *maintenance_capex_share* y en el percentil 90 para la brecha entre *distributable_cash_flow* y *free_cash_flow*.

Mirando el heatmap la empresa muestra cierta debilidad en la generación de caja, su margen de CFO está 0,8 desvíos por debajo de la mediana y su FCF 1,2 desvíos por debajo. Sin embargo, mantiene crecimiento positivo, resultado neto cercano a la mediana y leverage bajo. Podría tratarse de una empresa con dificultades de generación de caja, pero sin manipulación.




Análisis tres falsos negativos

Se seleccionaron las 3 empresas con **score igual a cero** que eran falsos negativos, es decir que eran fraude pero los flags no los pudieron identificar. Se observa que uno es un shenanigan estilo WorldCom, otro estilo Linn y otro New Century.

firm_id	sector	Score	Flag WorldCom	Flag Linn energy	Flag New Century	Flag Lehman	Shenanigan
F0574	Technology	0.0	0	0	0	0	WorldCom
F0062	Energy	0.0	0	0	0	0	Linn
F0204	Financials	0.0	0	0	0	0	New Century

A continuación dejamos un heatmap, para compararlos con la mediana del sector. Dos presentan señales de deterioro económico, mientras que el restante muestra indicadores relativamente sólidos.



- *F0574 (WorldCom)*: presenta todas las variables observadas debajo de la mediana del sector. La regla WorldCom busca márgenes y capex inusualmente elevados, por lo que el deterioro general de la empresa dificulta la identificación del patrón de capitalización de gastos.
- *F0062 (Linn)*: Esta empresa tiene crecimiento de revenues, márgenes de CFO, FCF, income superior a la mediana y poca deuda, por lo tanto sus indicadores generales muestran un desempeño sólido y las condiciones específicas de la regla Linn no se cumplieron simultáneamente.
- *F0204 (New Century)*: presenta menor crecimiento, menor generación de caja y un leverage superior a la mediana sectorial. Sin embargo, no se activó la regla porque los indicadores específicos de deterioro de NPL y cobertura crediticia no superaron simultáneamente los umbrales definidos.

Estos casos muestran que una manipulación puede quedar sin detectar tanto en empresas deterioradas como en empresas con buenos resultados. Al exigir que varias condiciones se

cumplan al mismo tiempo, las reglas reducen las falsas alertas, pero también pueden dejar fuera casos reales con señales menos extremas.

Discuta qué error considera más relevante en este contexto

Si tenemos que decidir que es más costoso entre las opciones de investigar una empresa que finalmente reportaba correctamente o dejar sin investigar una empresa que presentaba una manipulación, se considera que la opción más costosa es dejar sin investigar una empresa que presentaba manipulación, es decir un falso negativo. Es decir, que en el trade off precision and recall, el que más se debe priorizar es el recall. Por lo tanto el sistema actual resulta útil para priorizar empresas, pero su bajo recall indica que no debería utilizarse como único mecanismo de detección.

Parte II: Detección de fraude cost sensitive


Las preguntas 1 y 2 se hicieron en el archivo [eda_partell.ipynb](#), la 4 en [training.ipynb](#) y la 5 se hizo en el excel `umbral_fraude_cost_sensitive_correa_1pct` y en los dos notebooks anteriores.

1. Análisis exploratorio del dataset.


a. Algunos gráficos pueden ayudarlo a entender mejor el problema.

Se realizó un análisis exploratorio de la base de **train** mediante un Pandas Data Profiling ([reporte_ydata_profiling_partell.html](#)) y diferentes visualizaciones de las variables más relevantes. El dataset contiene 1.296.675 transacciones y 23 variables, sin valores faltantes. Uno de los principales aspectos observados es el fuerte desbalance de la variable objetivo `is_fraud`: aproximadamente el 99,4 % de las transacciones corresponden a operaciones no fraudulentas. Además, la variable `amt` presenta una distribución fuertemente asimétrica, lo que posteriormente motivó analizar su transformación logarítmica.


Los gráficos permiten visualizar estas características y explorar diferencias en los montos, categorías y características temporales de las transacciones fraudulentas y no fraudulentas. Con respecto a la demografía de los clientes pudimos observar que la edad de los que realizaban transacciones se encontraba variada e incluía individuos menores de edad.






Y que el género de los clientes era un 54.7% femenino y un 45.3% masculino.



Sobre la temporalidad de las transacciones y su relación al fraude, analizamos las transacciones en función de la hora, el día, el mes y el año.






Encontramos que la hora era una variable clave para el fraude, donde la mayor tasa de fraude sucede durante la noche. Conclusión que nos llevó mas adelante a construir una variable de transacciones nocturnas.

Sobre la latitud y longitud de las transacciones, encontramos que todas se encuentran ubicadas en los Estados Unidos. Notar que los puntos que parecen estar en el océano son

los estados de Alaska y Hawaii.



Existen muchas variables categóricas, que deben ser tratadas de forma especial. No todas van a ser utilizadas en el modelo, por ejemplo en lugar de las categóricas de state, city y street se decidió utilizar latitud y longitud por simplicidad. La cardinalidad de las variables categóricas es altísima, como se ve a continuación:



merchant (693 únicas)



category (14 únicas)



first (352 únicas)



last (481 únicas)





b. ¿Es necesario realizar una reducción de dimensionalidad para alguna de estas visualizaciones?

Para la mayoría de los gráficos no fue necesario reducir la dimensionalidad, ya que analizan una variable a la vez.

Sin embargo, para visualizar los clusters se utilizó PCA, dado que fueron contruidos a partir de seis variables. PCA permitió resumir esta información en dos dimensiones y representarla gráficamente. Los clusters se estimaron sobre las variables originales estandarizadas; PCA se utilizó únicamente como herramienta de visualización.

c. ¿Existen outliers?

Sí. Se identificaron valores extremos principalmente en la variable amt (monto de la transacción), cuya distribución presenta una fuerte asimetría hacia la derecha. Esto puede observarse tanto en el histograma como en el boxplot del monto original.



Sin embargo, estos valores no fueron eliminados automáticamente, ya que en un problema de detección de fraude una transacción con un monto inusual puede contener información relevante. Para reducir la asimetría y facilitar su análisis, se generó la variable `log_amt`, aplicando una transformación logarítmica al monto.


d. ¿Podemos encontrar clusters (sin usar el target) en los datos? Este punto es relevante porque podría ocurrir que la variable de target haya identificado como fraude solamente en algunos casos. Esto podría ocurrir porque confirmar el fraude requiere un proceso costoso que probablemente sólo se realiza sobre algunas observaciones identificadas previamente como sospechosas.

Armamos un [análisis de clusters](#) utilizando únicamente las transacciones del **train**. Se seleccionaron las siguientes variables, que escalamos con un `StandardScaler` para evitar que las diferencias de escala determinarán artificialmente las distancias.

<i>Variable</i>	<i>Definición</i>
<i>log_amt</i>	<i>Monto de la transacción en escala logarítmica</i>
<i>age</i>	<i>Edad del cliente al momento de hacer la transacción</i>

<i>dif_lat</i>	<i>Diferencia de latitud entre el cliente y el comercio</i>
<i>dif_long</i>	<i>Diferencia de longitud entre el cliente y el comercio</i>
<i>city_pop</i>	<i>Población de la ciudad de residencia del cliente</i>
<i>night_flag</i>	<i>Vale 1 si la transacción se realizó entre las 22:00 y las 03:59; 0 en caso contrario</i>


Se decidió utilizar un algoritmo Kmeans, para lo que primero se debió seleccionar el valor de K, en función de las métricas de inercia, Silhouette, Calinski-Harabasz y Davies-Bouldin. Probamos valores de k entre 2 y 8. No encontramos una cantidad de clusters que fuera claramente superior según todas las métricas, donde k=2 obtuvo el mayor Silhouette, mientras que k=4 presentó el mejor valor de Calinski-Harabasz, una reducción importante de la inercia y grupos más equilibrados




Seleccionamos K = 4, en función de el codo que se ve la inercia y que tiene valores razonables de las otras 3 métricas. Además, permitió obtener grupos más interpretables que con k=3, donde una gran parte de las observaciones quedaba concentrada en un único cluster. Sin embargo el Silhouette cercano a 0,19 indica que los grupos no están completamente separados y que existe cierto grado de superposición.

Se realizó un PCA con el único objetivo de poder graficar con los dos primeros componentes

los clusters, se puede ver que el cluster 1 tiene la mayor parte del fraude.



Se realizó un diagrama polar para poder interpretar los 4 clusters. El grupo más relevante es el cluster 1, caracterizado principalmente por operaciones nocturnas, montos más altos y clientes de mayor edad. Este cluster presenta una tasa de fraude del 2,08%, considerablemente superior a la del resto de los grupos y aproximadamente 3,6 veces mayor que la tasa general. El cluster 0 se diferencia por concentrar operaciones asociadas a ciudades con mayor población y presenta una tasa de fraude cercana al promedio general. Por su parte, los clusters 2 y 3 corresponden principalmente a operaciones diurnas y tienen tasas de fraude muy bajas. La diferencia entre ellos parece estar relacionada sobre todo con las variables geográficas, donde el cluster 2 presenta mayores diferencias de latitud, mientras que el cluster 3 se distingue por mayores diferencias de longitud.



En la tabla siguiente puede verse que el cluster 1 reúne el 22,8% de las operaciones, pero aproximadamente el 82% de los fraudes conocidos.

cluster	transacciones	fraudes	fraude %	transacciones %	total fraudes %
0	41734	238	0.57%	3.22%	3.17%
1	295822	6160	2.08%	22.81%	82.07%
2	479773	573	0.12%	37.00%	7.63%
3	479346	535	0.11%	36.97%	7.13%

En conclusión, los clusters parecen representar perfiles operativos y geográficos más que grupos de fraude claramente separados. Sin embargo, el cluster 1 demuestra que el análisis no supervisado puede ser útil como herramienta de preselección, ya que permite identificar un conjunto de operaciones con una concentración de fraude superior al promedio. De todos modos, pertenecer a este grupo no implica que una transacción sea fraudulenta, solamente indica que comparte características con un perfil que podría justificar una revisión más detallada.

e. ¿Hay correlaciones entre los features? Recuerde el VIF.

Se [calculó](#) el VIF para detectar posibles problemas de multicolinealidad. Los valores obtenidos fueron bajos: el VIF máximo fue 2,63. Considerando que valores inferiores a 5 son generalmente aceptables, no se observan problemas relevantes de multicolinealidad entre las variables utilizadas.

Variable	VIF
Gas transport	2,63
Grocery POS	2,53
Shopping POS	2,15
Hora	2,11
Home	2,11
Kids & Pets	2,03
Shopping Net	1,98
Personal Care	1,85
Food & Dining	1,84
Misc POS	1,83

Health & Fitness	1,80
Log monto	1,79
Misc Net	1,74
Grocery Net	1,61
Monto	1,47
Travel	1,47
Año	1,28
Mes	1,28
Edad	1,10
Benford Surprisal 2D	1,08
Operación nocturna	1,03
Género masculino	1,01
Población ciudad	1,01
Día de la semana	1,00
Día	1,00
Diferencia latitud	1,00
Diferencia longitud	1,00

f. ¿Qué observaciones identificaría como sospechosas de fraude según los tests de dígitos en base a la ley de Benford?

Para analizar si los importes (variable amt) presentan patrones inusuales, [aplicamos los cinco tests de dígitos](#) propuestos por Nigrini: primer dígito, segundo dígito, primeros dos dígitos, primeros tres dígitos y últimos dos dígitos en la base de **train**. Siguiendo la metodología recomendada, excluimos las operaciones con importes menores a 10, ya que pueden distorsionar las distribuciones esperadas.

Para cada combinación de dígitos calculamos su proporción observada:

$$AP_d = \frac{n_d}{N}$$

donde n_d es la cantidad de operaciones correspondientes al dígito o grupo d , y N es el total de operaciones analizadas.

En los tests de primer dígito, primeros dos dígitos y primeros tres dígitos, la proporción esperada se calculó de la siguiente forma donde d representa el dígito analizado:

$$EP_d = \log_{10}\left(1 + \frac{1}{d}\right)$$

Para el segundo dígito, la proporción esperada es la siguiente, donde k representa cada posible primer dígito, entre 1 y 9. La probabilidad esperada se obtiene sumando las probabilidades de todas las combinaciones posibles.







$$EP_d = \sum_{k=1}^9 \log_{10} \left(1 + \frac{1}{10k+d} \right)$$


Finalmente una vez que tenemos las proporciones observadas y las esperadas en función de la Ley de Benford, realizamos el cálculo de z con la siguiente fórmula para evaluar si la diferencia entre la proporción observada y la esperada era estadísticamente relevante.

$$Z_d = \frac{|AP_d - EP_d| - \frac{1}{2N}}{\sqrt{\frac{EP_d(1-EP_d)}{N}}}$$

Se utilizó como referencia un nivel de significatividad del 5%. Por lo tanto, una combinación se consideró significativamente diferente de la distribución esperada cuando $Z_d > 1,96$.

Los resultados obtenidos para cada test se muestran en los siguientes gráficos. Se observa que los tests generales muestran que la distribución de los importes no se ajusta completamente a la Ley de Benford. En el test del primer dígito se observa una sobrerrepresentación de los valores entre 5 y 8, especialmente del 7, mientras que los dígitos 1, 2 y 3 aparecen con una frecuencia menor a la esperada. En el segundo dígito las diferencias son más pequeñas, aunque se destaca una mayor presencia del 0. Al analizar los primeros dos dígitos, las desviaciones se concentran principalmente alrededor de los grupos 74 y 75. En la distribución de los últimos dos dígitos se mantiene bastante cerca del 1% esperado para cada terminación. Esto indica que no se observa un patrón fuerte de redondeo o de uso repetido de determinadas terminaciones.





Para identificar operaciones sospechosas se seleccionó el **test de los primeros dos dígitos**, porque ofrece un nivel intermedio de detalle: el primer dígito produce grupos demasiado amplios, mientras que los primeros tres dígitos generan una segmentación mucho más granular.

Entre los grupos con una desviación positiva y estadísticamente significativa, se seleccionaron los dos con mayor estadístico Z: 74 y 75. Las transacciones cuyos importes comienzan con estos dígitos fueron identificadas como candidatas para una revisión más detallada. Este método permite detectar operaciones inusuales, aunque una desviación respecto de la Ley de Benford no implica necesariamente que exista fraude.

En la última sección de la parte 2, analizamos la performance OOS de este flag de operaciones sospechosas.

2. Ingeniería de Features

o ¿Necesita corregir valores faltantes?

No fue necesario realizar un tratamiento de valores faltantes. Luego de la ingeniería de features, la base utilizada para el modelado quedó conformada por 1.296.675 observaciones y 27 predictores, sin valores nulos en los features seleccionados.

o ¿Encuentra valores de los features que parecen errores en los datos?

Se detectó una inconsistencia en `unix_time`. Al convertirla a fecha, los valores corresponden aproximadamente a los años 2012-2013, mientras que `trans_date_trans_time` registra operaciones de 2019-2020. Ambas variables deberían representar el momento de la misma transacción, pero presentan un desfase cercano a siete años. Por este motivo, `unix_time` no fue utilizada y las variables temporales (año, mes, día y hora) se construyeron a partir de `trans_date_trans_time`.

Se observaron valores extremos principalmente en la variable `monto` (`amt`). Sin embargo, no se identificaron como errores de carga, ya que en un problema de detección de fraude las operaciones con montos inusuales pueden contener información relevante.

Para reducir la asimetría de esta variable se creó `log_amt`, aplicando una transformación logarítmica al monto.

o ¿Qué preprocesamiento necesitan las variables para los algoritmos de ensamble (bagging y random forest) que va a utilizar?

Para utilizar modelos de ensamble basados en árboles, como Bagging y Random Forest, fue necesario transformar las variables categóricas a formato numérico. En particular, la variable `category` fue transformada mediante one-hot encoding.

También se generaron nuevas variables numéricas a partir de la información original, como `log_amt`, `age`, `male`, `dif_lat`, `dif_long` y `benford_surprisal_2d`. No fue necesario estandarizar las variables numéricas, ya que los modelos basados en árboles realizan divisiones según puntos de corte y no dependen de la escala de los predictores. Las variables categóricas de alta cardinalidad, como `merchant`, `city`, `street` y `job`, no fueron incluidas para evitar generar una cantidad excesiva de columnas.

o ¿Podríamos probar diferentes estrategias para recodificar las variables categóricas como one hot encoding y target encoding?

Si, hay varias estrategias posibles, elegimos one-hot encoding porque las categorías no tienen un orden natural entre sí. Este método transforma cada categoría en una variable binaria independiente, evitando asignar un orden artificial a los datos. Además, es un método simple, fácil de interpretar y adecuado para trabajar con las variables categóricas de nuestra base.

El target encoding sería especialmente útil para variables con muchas categorías, como `merchant`, `city` o `job`, ya que permite representarlas sin generar cientos de columnas. Sin embargo, al utilizar información del target, debe calcularse únicamente sobre `train` y dentro de cada fold de validación cruzada para evitar data leakage. Además, con una clase tan desbalanceada podría generar sobreajuste en categorías con pocas observaciones.

Siguiendo un criterio de parsimonia, elegimos one-hot encoding únicamente para `category`, que tiene pocas categorías y es fácil de interpretar, y no incorporamos las variables de

mayor cardinalidad. El target encoding podría evaluarse como una extensión, pero no era necesario para construir un modelo razonable y reproducible.

3. La variable de target desbalanceada.

- **¿Qué cuidados debe tener al hacer el Split en train y test?**

Dado que la variable `is_fraud` está fuertemente desbalanceada, el split debe realizarse de forma estratificada, manteniendo aproximadamente la misma proporción de fraudes y no fraudes en Train y Test. En este trabajo utilizamos la separación entre Train y Test provista en la base, que respeta el orden temporal de las transacciones y además tiene % de fraude similares. Además el conjunto de Test se mantuvo fuera del entrenamiento, la selección de hiperparámetros y la elección del umbral.

Por otro lado, es importante que cualquier técnica de rebalanceo se aplique solamente sobre el conjunto de Train. El conjunto de Test debe conservar la distribución original de los datos para evaluar el desempeño del modelo en condiciones similares a las reales.

Esto evita también data leakage, es decir, que información del conjunto de Test influya en el entrenamiento del modelo.

¿Qué estrategias podría usar para rebalancear el dataset?

Dado el fuerte desbalance de la variable objetivo, donde las transacciones fraudulentas representan menos del 1% del total, se pueden utilizar distintas estrategias de rebalanceo. Entre ellas se encuentran el Random Oversampling, que aumenta la representación de la clase minoritaria replicando observaciones, el Random Undersampling, que reduce la cantidad de observaciones de la clase mayoritaria y SMOTE, que genera observaciones sintéticas de la clase minoritaria a partir de casos similares. Otra alternativa es utilizar `class_weight`, asignando mayor importancia a la clase minoritaria durante el entrenamiento.

En este trabajo decidimos no aplicar técnicas de remuestreo. El undersampling implicaría descartar una gran cantidad de operaciones legítimas, y el oversampling implicaría repetir muchas veces las mismas operaciones fraudulentas, con el riesgo de que el modelo aprenda casos particulares y pierda capacidad de generalización. Además, modificar artificialmente la proporción de fraude, con cualquiera de estas técnicas puede afectar la calibración de las probabilidades, introducir sesgo y dejar de ser representativo de la realidad. En una iteración posterior puede analizarse el efecto en la performance out of sample de un modelo entrenado utilizando estas técnicas, pero no es algo que en la práctica se deba aplicar por defecto, los modelos como Random Forest son buenos manejando clases desbalanceadas.

Por otra parte `class_weight='balanced'` fue incluido entre los hiperparámetros evaluados, pero la búsqueda seleccionó `class_weight=None`. Por lo tanto, mantuvimos la distribución original de train y abordamos el desbalance utilizando PR-AUC como criterio de evaluación y optimizando posteriormente el umbral según los costos de los falsos positivos y falsos negativos.

4. Entrenamiento random forest.

a. ¿Cuáles son los hiper parámetros en random forest?

Los hiperparámetros son valores definidos antes del entrenamiento que controlan cómo se construye el Random Forest.

Los principales son:

- *n_estimators*: cantidad de árboles.
- *max_depth*: profundidad máxima de cada árbol.
- *min_samples_split*: cantidad mínima de observaciones para dividir un nodo.
- *min_samples_leaf*: cantidad mínima de observaciones en cada hoja.
- *max_features*: cantidad de variables consideradas en cada división.
- *class_weight*: peso asignado a cada clase.
- *criterion*: criterio utilizado para elegir las divisiones.
- *bootstrap*: indica si cada árbol se entrena con una muestra con reemplazo

En este trabajo se optimizaron *n_estimators*, *max_depth*, *min_samples_leaf* y *class_weight*.

b. ¿Cuáles de esos hiper parámetros pueden generar sobreajuste?

Los hiperparámetros que más pueden generar sobreajuste son:

- *max_depth*: una profundidad muy alta permite que cada árbol aprenda patrones demasiado específicos del entrenamiento.
- *min_samples_split*: si es muy bajo, permite seguir dividiendo nodos con pocos casos.
- *min_samples_leaf*: valores muy bajos, como 1, generan hojas basadas en pocas observaciones.
- *max_features*: considerar muchas variables en cada división puede reducir la diversidad entre los árboles.

c. Entrenamiento modelo

Para [entrenar el Random Forest](#) se seleccionaron y armaron las siguientes variables:

Variable	Definición
<i>log_amt, amt</i>	<i>Variables de Monto</i>
<i>age, male</i>	<i>Demografía del cliente</i>
<i>dif_lat, dif_long, city_pop</i>	<i>Ubicación del cliente</i>
<i>Category_XXX</i>	<i>Variables de categoría de comercio</i>
<i>benford_surprisal_2d</i>	<i>Este score mide la rareza teórica del patrón de dos dígitos bajo Benford</i>
<i>day, month, year, hour, day_of_week, night_flag</i>	<i>Variables de temporalidad</i>

Modelo Baseline

Con estas variables entrenamos en un primer momento un modelo baseline, sin tuneo de hiperparámetros, utilizando únicamente los que vienen por default. Utilizamos **validación cruzada estratificada de cinco folds**, tanto en el modelo Baseline como en el final. En el modelo Baseline se utilizó para estimar el desempeño promedio del baseline, ver si el resultado cambia mucho entre folds, comparar train contra validación para detectar sobreajuste y tener un punto de referencia justo para evaluar si la optimización posterior realmente mejora el modelo.

La estratificación permitió mantener una proporción similar de fraudes en cada partición, algo especialmente importante debido al fuerte desbalance del target.

Las observaciones se mezclaron antes de construir los folds y se fijó una semilla para garantizar la reproducibilidad. Como limitación, esta estrategia no preserva el orden temporal dentro del conjunto de entrenamiento. Sin embargo, el conjunto de test, correspondiente a un período posterior, se mantuvo completamente separado y se utilizó únicamente para la evaluación final. Buscamos asegurar la representación de la clase minoritaria durante la optimización y dejamos la evaluación temporal estricta para el conjunto de test.

En la siguiente tabla se comprueba como cada fold tiene la misma cantidad aproximada de fraude.

Fold	Observaciones	Fraudes	Tasa de fraude
1	259,335	1,501	0.579%
2	259,335	1,501	0.579%
3	259,335	1,501	0.579%
4	259,335	1,501	0.579%
5	259,335	1,502	0.579%

Los resultados de cada fold del baseline son los siguientes, donde el PR-AUC promedio del baseline 0,9071.

Como el fraude es una clase muy minoritaria, usamos PR-AUC como métrica principal y ROC-AUC como métrica complementaria para hacer un chequeo de los resultados de validación. También comparamos el PR-AUC de entrenamiento y validación para detectar un posible sobreajuste.

Fold	PR-AUC train	PR-AUC validation	ROC-AUC train	ROC-AUC validation
1	1.0	0.9093	1.0	0.9892
2	1.0	0.9012	1.0	0.9833
3	1.0	0.9074	1.0	0.9859
4	1.0	0.9089	1.0	0.9858
5	1.0	0.9088	1.0	0.9861

Los resultados de validación son bastante estables entre los cinco folds. El PR-AUC promedio es de aproximadamente 0,907 y el ROC-AUC promedio es de 0,986, con poca

variación entre las particiones. Sin embargo, ambas métricas alcanzan un valor de 1 en entrenamiento, lo que muestra que el Random Forest con sus parámetros por defecto se ajusta demasiado a los datos utilizados para entrenar. Por lo tanto, el modelo baseline presenta un buen poder predictivo, pero también evidencia de sobreajuste.

Modelo Optimizado

Posteriormente se entrenó otro Random Forest, pero a diferencia del anterior se optimizaron parámetros con validación cruzada.

Se seleccionaron hiperparámetros vinculados tanto con la complejidad del modelo como con el desbalance de clases. Se probaron distintas cantidades de árboles, niveles de profundidad y tamaños mínimos de las hojas, buscando comparar modelos más flexibles con alternativas más regularizadas. También se evaluó el uso de ponderación automática de las clases. La cantidad de combinaciones analizadas se limitó debido al costo computacional asociado al tamaño del conjunto de entrenamiento.

La optimización se realizó mediante RandomizedSearchCV, que evalúa una cantidad limitada de combinaciones de hiperparámetros seleccionadas aleatoriamente. Cada combinación fue evaluada mediante validación cruzada estratificada de cinco folds, utilizando PR-AUC como criterio de selección. Este método permitió explorar distintas configuraciones del modelo con un costo computacional menor que una búsqueda exhaustiva. Finalmente, la combinación con mayor PR-AUC promedio (Mejor PR-AUC: 0.9131) fue reentrenada utilizando la totalidad del conjunto de train.

Hiperparámetros	Rango	Seleccionado
n_estimators	[100, 200, 300]	200
max_depth	[10, 15, 20]	20
min_samples_leaf	[1, 5, 20]	1
class_weight	[None, 'balanced']	None

Los resultados de los folds se detallan a continuación, continuamos con una diferencia de PR-AUC entre train y validation, lo que es esperable pero puede ser una señal de un poco de overfitting.

Fold	PR-AUC train	PR-AUC validation	ROC-AUC train	ROC-AUC validation
1	0.9997	0.9144	1.0	0.9965
2	0.9997	0.9069	1.0	0.9964
3	0.9997	0.9133	1.0	0.9967
4	0.9996	0.9150	1.0	0.9956
5	0.9996	0.9159	1.0	0.9969

En comparación con el baseline, cuyo PR-AUC promedio era de 0,9071, se observa una mejora moderada en la métrica utilizada para seleccionar el modelo. Sin embargo, el

PR-AUC de entrenamiento se mantiene cercano a 1, por lo que la optimización mejoró el desempeño de validación, pero no eliminó completamente el sobreajuste. Por este motivo, el resultado definitivo debe evaluarse sobre el conjunto de test temporal, que no participó del entrenamiento ni de la selección de hiperparámetros.



Performance en Universo Test con Umbral Genérico

Hasta ahora el entrenamiento de los dos modelos, el tuneo de los hiperparámetros, las mediciones de performance se hicieron en la base de train. A continuación analizamos la performance en la base de Test, que se mantuvo separado durante todo el proceso, para analizar su desempeño sobre datos no vistos. Para las métricas que requieren un umbral se utilizó un umbral de 0.5, en la sección siguiente se optimizó el umbral de clasificación

En la tabla siguiente se muestran los resultados, donde el modelo optimizado logra una mejora moderada en PR-AUC, que pasa de 0,8703 a 0,8770, y en ROC-AUC, que aumenta de 0,9836 a 0,9950. También mejora levemente la precisión, aunque presenta un recall apenas menor. En términos generales, la optimización no produce un cambio drástico, pero mejora ligeramente la capacidad del modelo de predecir fraude.

	accuracy	precision	recall	f1	roc_auc	pr_auc
Baseline	0.9988	0.9350	0.7506	0.8327	0.9836	0.8703
Optimizado	0.9988	0.9391	0.7473	0.8323	0.9950	0.8770

La performance Out of sample es muy buena, tanto del modelo baseline como del optimizado. Idea que se refuerza cuando vemos los siguientes gráficos de la PR curve y la ROC AUC del modelo optimizado. Las curvas muestran que el modelo tiene una buena capacidad para distinguir las transacciones fraudulentas de las legítimas. La curva ROC se mantiene cerca del extremo superior izquierdo y alcanza un AUC de 0,99. Por su parte, la curva Precision-Recall obtiene un AP de 0,88, un resultado especialmente relevante debido al fuerte desbalance de la base.



Estas métricas no dependen del Umbral, más adelante hacemos un análisis para determinar el umbral con una metodología cost sensitive.

5. Estimación de los costos de cada tipo de error en la clasificación y plantee la matriz de costos de clasificación.

Dado que los errores de clasificación no tienen la misma consecuencia económica, se definió una matriz de costos diferenciada para cada posible resultado del modelo. En particular, se asumió un costo administrativo de \$5 tanto para un verdadero positivo como para un falso positivo, asociado al proceso de revisión, contacto o bloqueo de una transacción. Para los falsos negativos se estableció un costo de \$500, equivalente a 100 veces el costo administrativo, ya que un falso negativo resulta más costoso que una alerta innecesaria porque implica dejar pasar una operación fraudulenta, mientras que los verdaderos negativos no generan costo.

Costo verdadero positivo CTP (\$)	\$5,00
Costo falso positivo CFP (\$)	\$5,00
Costo falso negativo CFN (\$)	\$500,00
Costo verdadero negativo CTN (\$)	-

Para optimizar el umbral de clasificación se trabajó solo con una de las **predicciones out of fold** de los cinco folds estratificados del **train**. Es decir, que se entrenó con los 4 otros folds, se predijo el 5to fold como grupo de validación y este se seleccionó para optimizar el umbral. Dado que cada fold conserva aproximadamente la distribución de la variable objetivo y contiene una muestra suficientemente grande, se utilizó solo un fold de 259.335 observaciones con el objetivo de mantener un volumen de datos manejable en Excel y Solver.

Mediante solver, se optimizó dicho umbral planteando como objetivo maximizar el ahorro económico en función del costo de los errores, calculado con la siguiente función: $\text{Costo} = TP \times CTP + FP \times CFP + FN \times CFN + TN \times CTN$, el cual compara el costo sin modelo considerando todas las operaciones como legítimas vs el costo con el umbral elegido, sujeto a la siguiente restricción $0 \leq \text{Valor umbral} \leq 1$. El ahorro que genera el modelo es del 93.17%, ya que con los costos definidos, el costo del escenario sin modelo asciende a \$750.500 vs \$51.280 y el umbral optimizado dio como resultado 2,63%. Esto implica que, a efectos de la regla de clasificación, toda transacción cuya probabilidad estimada de fraude sea igual o superior al 2,63% se clasifica como potencial fraude y queda sujeta a revisión.

A continuación se presenta el resultado de la matriz de confusión en cantidades y la contribución al costo total según los costos definidos para cada tipo de error para el fold bajo análisis:

Matriz de confusión en cantidades

	Positive	Negative	Total
Fraude	1442	59	1501
Legítima	2914	254.920	257.834

Total	4.356	254.979	259.335
-------	-------	---------	---------

De las 1.501 operaciones fraudulentas, el modelo identifica correctamente 1.442 y deja sin detectar 59. A su vez, clasifica como fraude 2.914 operaciones que en realidad eran legítimas.

Contribución al costo total

	Positive	Negative	Total
Fraude	\$7.210	\$29.500	\$36.710
Legítima	\$14.570	-	\$14.570
Total decisión	\$21.780	\$29.500	\$51.280

La mayor contribución al costo total proviene de los falsos negativos, aun cuando representan solamente 59 observaciones.

Las métricas del modelo con el umbral optimizado en el fold que se utilizó para optimizar el umbral son las siguientes

- Accuracy 98,85%
- Recall de fraude 96,07%
- Precisión 33,10%
- Tasa de falsos positivos 1,13%

El recall de fraude de 96,07% indica que el modelo detecta aproximadamente 96 de cada 100 operaciones fraudulentas.

La precisión de 33,10% implica que aproximadamente una de cada tres operaciones clasificadas como fraude resulta efectivamente fraudulenta. Si bien este valor puede parecer relativamente bajo, debe interpretarse conjuntamente con la estructura de costos: el objetivo no es minimizar el número de falsos positivos, sino reducir el costo económico total de los errores.

Asimismo, el accuracy de 98,85% continúa siendo elevado debido al fuerte desbalance de la variable objetivo. Sin embargo, en este contexto no constituye la principal medida de desempeño, ya que una elevada proporción de operaciones legítimas puede producir valores altos de accuracy incluso en modelos con escasa capacidad para detectar fraude.

El umbral puede considerarse un hiper parámetro de la regla de decisión aunque no es un hiper parámetro interno del Random Forest, por lo que modificarlo no cambia la estructura ni el entrenamiento de los árboles, pero sí modifica la cantidad de verdaderos positivos, falsos positivos, falsos negativos y verdaderos negativos.

Conceptualmente, la optimización del umbral podría incorporarse dentro del esquema de validación cruzada. En cada iteración se entrenaría el Random Forest sobre los folds de entrenamiento y se obtendrían probabilidades sobre el fold de validación. Sobre esas

probabilidades se evaluarían distintos valores del umbral y se calcularía el costo económico asociado a cada uno. El umbral seleccionado podría ser aquel que minimice el costo promedio entre todos los folds, o bien obtenerse a partir de predicciones out-of-fold de todo el conjunto de entrenamiento. Finalmente, ese umbral se aplicaría una única vez sobre el conjunto de test, que debería permanecer fuera del proceso de optimización.

Performance en Universo Test con Umbral Optimizado

Evaluamos la performance del modelo optimizado sobre la base de test, aplicando el umbral de 0,0263 seleccionado previamente a partir de las probabilidades out-of-fold del conjunto de entrenamiento.

En la siguiente tabla mostramos la performance del modelo optimizado con el umbral genérico de 0,5 vs el que tiene el umbral optimizado. Vemos cómo cambia la relación de trade off entre precision y recall.

Al reducir el umbral de 0,50 a 0,0263, el recall aumenta de 74,73% a 94,13%, por lo que el modelo logra detectar una proporción mucho mayor de los fraudes. Como contrapartida, la precisión disminuye de 93,91% a 25,77%, ya que también aumenta la cantidad de operaciones legítimas clasificadas como sospechosas.

Modelo	Umbral	accuracy	precision	recall	f1
Optimizado	0.5	0.9988	0.9391	0.7473	0.8323
Optimizado+umbral	0.0263	0.9893	0.2577	0.9413	0.4046

Matriz de confusión					
Modelo	Umbral	TP	FN	FP	TN
Optimizado	0.5000	1603	542	104	553470
Optimizado+umbral	0.0263	2019	126	5815	547759


En términos absolutos, el nuevo umbral permite detectar 416 fraudes adicionales, pero genera 5.711 falsas alertas adicionales, como se observa en la siguiente matriz de confusión de las dos opciones.

Desde el punto de vista económico, este resultado es consistente con la matriz de costos definida. Un falso negativo, es decir, dejar pasar una operación fraudulenta, tiene un costo estimado de \$500, mientras que un falso positivo genera un costo de revisión de \$5. En este contexto, resulta razonable aceptar una menor precisión y una mayor cantidad de revisiones a cambio de aumentar el recall y reducir considerablemente los fraudes que quedan sin detectar. Por esta razón, aunque disminuyan el accuracy y el F1, el umbral optimizado puede representar una decisión económicamente más conveniente.

Importancia de los predictores vía permutation importance

Para analizar la importancia de los predictores utilizamos permutation importance sobre el conjunto de test, utilizando permutation_importance() de sklearn. La metodología consiste en mezclar aleatoriamente los valores de una variable, manteniendo las demás sin cambios, y volver a medir el desempeño del modelo. Si el PR-AUC disminuye de manera importante,

significa que el modelo dependía de esa variable para realizar sus predicciones. El procedimiento se repitió cinco veces por predictor para obtener un resultado más estable.



Los resultados muestran que `log_amt` es el predictor con mayor importancia, ya que su permutación genera la mayor caída del Average Precision. Esto indica que el monto de la transacción, transformado logarítmicamente, contiene una parte sustancial de la información que utiliza el Random Forest para distinguir entre operaciones fraudulentas y legítimas. A continuación aparecen `category_grocery_pos`, `amt`, `category_gas_transport`, `hour` y `age`. Esto indica que el modelo utiliza principalmente información relacionada con el monto, el tipo de comercio, el horario y la edad del cliente.

Por otra parte, variables como `night_flag`, `category_misc_pos`, `benford_surprisal_2d` y `category_grocery_net` presentan una importancia positiva pero bastante menor.

En particular, la variable `benford_surprisal_2d` aporta información adicional al modelo, aunque su contribución es sustancialmente inferior a la de variables como el monto, algunas categorías comerciales y la hora de la transacción.

Esto resulta consistente con la idea de que Benford puede aportar una señal complementaria, pero no concentra por sí sola la mayor parte de la capacidad predictiva del modelo.

Finalmente, variables como `month`, `year`, `dif_lat`, `dif_long`, `day_of_week` y `day` muestran una importancia cercana a cero, es decir una ausencia de una contribución predictiva estable.


Esto significa que, dado el resto de los predictores incluidos en el Random Forest, permutar estas variables prácticamente no modifica el Average Precision del modelo.

Análisis gráfico mediante Lift and gain charts

Se construyeron gráficos sobre las predicciones de test, ordenando las transacciones de mayor a menor según la probabilidad estimada por el modelo optimizado. El análisis de Gain muestra que el modelo presenta una fuerte capacidad de concentración del fraude en las observaciones con mayor probabilidad estimada.


Al ordenar las transacciones de mayor a menor probabilidad de fraude se observa lo siguiente:

- Revisando aproximadamente el 10% de las transacciones con mayor riesgo, se detecta cerca del 99% de los fraudes;
- Al alcanzar aproximadamente el 20% de la población, la detección acumulada es prácticamente del 100%.




Esto indica que el modelo permite priorizar de manera muy eficiente las operaciones que deberían ser revisadas, reduciendo sustancialmente la cantidad de transacciones que requerirían intervención manual.

El gráfico de Lift acumulado refuerza esta conclusión. En el primer decil, el lift es cercano a 9,8, lo que significa que el 10% de las operaciones clasificadas como de mayor riesgo concentra aproximadamente 9,8 veces más fraudes que una selección aleatoria de igual tamaño. A medida que se incorporan más deciles, el lift disminuye progresivamente hasta aproximarse a 1, lo cual es esperable: una vez revisadas las operaciones de mayor riesgo, los deciles restantes contienen cada vez menos casos fraudulentos.



Estadístico KS



El gráfico de KS muestra una separación muy elevada entre fraudes y no fraudes, con una diferencia máxima cercana a 89 puntos porcentuales. Esto indica una fuerte capacidad discriminante del modelo: las operaciones fraudulentas quedan concentradas en los primeros niveles del ranking de riesgo, mientras que las legítimas se distribuyen predominantemente en los deciles posteriores.

Los resultados de Lift y Gain muestran que el Random Forest posee una elevada capacidad para ordenar las transacciones según su riesgo de fraude. El primer 10% de operaciones con mayor probabilidad concentra aproximadamente el 99% de los fraudes, con un lift cercano a 9,8 respecto de una selección aleatoria. En términos operativos, esto permite plantear una estrategia de revisión focalizada, concentrando los controles sobre una fracción reducida de las transacciones y manteniendo prácticamente toda la capacidad de detección del modelo.

Comparación de resultados en cuanto a las observaciones identificadas como sospechosas de fraude en base a tests de dígitos versus machine learning cost sensitive.

Comparamos los resultados obtenidos sobre la base de test por el modelo cost-sensitive y por el flag construido a partir de Benford. Se observa que el modelo es ampliamente superior en todas las métricas de performance. Esto refuerza la idea de que Benford puede utilizarse como una señal complementaria o incorporarse como predictor, pero no reemplaza al modelo supervisado.

Modelo	accuracy	precision	recall	f1
Optimizado+umbral	0.9893	0.2577	0.9413	0.4046
Flag Benford	0.9808	0.004	0.0158	0.0063

Sobre un total de 2.145 operaciones fraudulentas, el modelo cost-sensitive detecta correctamente 2.019 y deja sin identificar 126. En cambio, el flag de Benford detecta solamente 34 fraudes y deja pasar 2.111. Además, Benford genera más alertas en total que el modelo (8.561 frente a 7.834), pero una proporción mucho mayor corresponde a operaciones legítimas. Esto se refleja en sus 8.527 falsos positivos, frente a los 5.815 del modelo. Por lo tanto, el modelo cost-sensitive no solo detecta una cantidad considerablemente mayor de fraudes, sino que también genera menos falsas alertas.

Modelo	TP	FN	FP	TN
Optimizado+umbral	2019	126	5815	547759
Flag Benford	34	2111	8527	545047

Debe aclararse que el modelo incluye benford_surprisal_2d como predictor. Sin embargo, su importancia dentro del modelo es considerablemente menor que la de variables como el monto, categoría y hora. Esto refuerza la idea de que Benford puede aportar una señal complementaria, pero no reemplaza al modelo supervisado para identificar operaciones fraudulentas.

Anexo Final

Uso de la IA

En este trabajo se utilizó a la IA en primer lugar para entender conceptos complejos de la bibliografía que no habíamos aplicado nunca, como la Ley de Benford, y a interpretar las diferencias entre las distintas metodologías y fuentes consultadas. En segundo lugar en tareas de redacción, nos ayudó a que nuestros escritos comuniquen lo que queremos expresar, y revisar que no tengamos inconsistencias intra texto de este escrito que tiene casi 60 páginas.

Por último, recurrimos a herramientas de autocompletado y asistencia para programar con mayor rapidez y resolver errores puntuales de código.

Todas las decisiones metodológicas, los supuestos y la interpretación de los resultados fueron revisados por el equipo. Las fórmulas se contrastaron con la bibliografía, los cálculos se verificaron con las salidas de las notebooks y el código se leyó y contrastó en cada línea y resultado obtenido. Se hizo mucho énfasis en que el código sea legible, sencillo y correcto, pero que lleve a la realidad los análisis y modelos que deseábamos realizar.

Reflexión Final

El trabajo final nos permitió reforzar los conceptos aprendidos en clase, especialmente aquellos más alejados de nuestros conocimientos previos. Aprendimos sobre la ley de Benford como una herramienta que puede aportar señales para la detección de fraude, pero también comprobamos que no debe utilizarse como único mecanismo de detección. Además, aprendimos a optimizar el umbral de clasificación con un enfoque cost-sensitive y a construir flags a partir de reglas de negocio.

Una de las principales dificultades al modelar estuvo relacionada con nuestras limitaciones de capacidad de procesamiento. Intentamos utilizar Orange, pero tuvimos problemas para procesar los 1,2 millones de observaciones del conjunto de entrenamiento de la Parte II. Finalmente, decidimos realizar el análisis en Python, ya que teníamos experiencia previa programando y tanto pandas como scikit-learn permitieron trabajar con este volumen de datos. Aun así, por el costo computacional de RandomizedSearchCV, no pudimos realizar una búsqueda de hiperparámetros más extensa.

Esta limitación también hizo necesario utilizar solamente uno de los folds de la validación cruzada para optimizar el umbral con Solver en Excel. Incluso con esta solución intermedia, Excel dejó de responder en más de una oportunidad.

Por último, aunque el trabajo nos permitió aprender mucho, su extensión representó otro desafío. Comenzamos a trabajar apenas recibimos las consignas, pero de todas formas el tiempo disponible nos resultó ajustado.

Si hubiéramos tenido más tiempo, habríamos profundizado el análisis de clustering de la Parte I. Algunas pruebas quedaron únicamente como borradores de código y no fueron incorporadas al trabajo, que ya era muy extenso. Nos habría gustado incluir los clusters contruidos por sector y explorar otras configuraciones. A pesar de nuestras intenciones iniciales, los grupos obtenidos terminaron reflejando principalmente diferencias sectoriales y de tamaño, en lugar de perfiles claramente asociados con los distintos tipos de shenanigans.

Además, podríamos haber mejorado el sistema de detección basado en Benford mediante nuevas iteraciones sobre la base de entrenamiento y validación. Su desempeño tanto in-sample como out-of-sample fue relativamente bajo. Es posible que una regla más elaborada hubiera mejorado los resultados, aunque probablemente a costa de una mayor complejidad y una menor interpretabilidad.

Entre los supuestos más importantes estuvo la elección de los costos asociados a cada tipo de error, ya que la relación definida entre falsos negativos y falsos positivos determinó el

umbral óptimo del modelo. También asumimos que las etiquetas disponibles representan correctamente los casos de fraude y que los patrones observados en train se mantienen en test. Estos supuestos fueron necesarios para realizar el análisis, pero en una aplicación real deberían validarse con información histórica y conocimiento del negocio.